




인공지능

Artificial Intelligence






딥러닝과 파이토치

MLP→DNN

본 강의자료는 한빛아카데미 <파이썬으로 만드는 인공지능>을 내용을
기반으로 제작 및 보완되었음을 알립니다.



5.1 딥러닝의 등장

- 딥러닝의 등장이 늦어진 이유
 - 깊은 신경망(딥러닝)에 대한 아이디어는 다층 퍼셉트론(MLP)이 등장해 혁신을 이루던 1980년대에 이미 나왔었음.
 - 다층 퍼셉트론에 은닉층을 여러 개 추가하면 깊은 신경망이 되기 때문에 누구나 쉽게 생각할 수 있었으나, 은닉층을 추가해 신경망을 깊게 만들면 제대로 학습되지 않는 문제가 있었음.
- 깊은 신경망 학습에 번번이 실패하는 이유
 - 1) 오류 역전파 알고리즘은 출력층에서 시작해 입력층 방향으로 진행하면서 그레디언트 미분값을 계산하고 가중치를 갱신하는데, 단계적으로 여러 층을 거치면서 그레디언트 값이 점점 작아져 입력층에 가까워지면 변화가 거의 없는 **그레디언트 소멸 문제** `gradient vanishing` 가 발생함
 - 2) 훈련 집합의 크기는 작은 상태로 머물러 있는데 추정할 매개변수는 크게 늘어 **과잉 적합** `over-fitting`에 빠질 위험이 더욱 커짐
 - 3) 학습이 어려운 또 다른 이유는 **과다한 계산 시간**임. 예전에는 병렬 처리를 하려면 값비싼 슈퍼컴퓨터를 사용하는 수밖에 없었음. (GPU의 등장으로 해당 문제 해결)

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 요인
 - 딥러닝의 등장 및 부상에 새롭게 제안된 이론이나 원리는 별로 없음
 - 신경망의 기본 구조와 동작, 학습 알고리즘의 기본 원리는 동일함
 - **저렴한 GPU 등장**
 - 성능이 뛰어나고 상대적으로 가격이 저렴한 GPU가 등장하면서, 대학 실험실에서도 손쉽게 병렬 처리 연산을 할 수 있게 되었음
 - 학습 시간이 10~100배 단축으로 다양한 실험을 시도 할 수 있게 되었음
 - 예들 들어, 딥러닝 모델 하나를 학습하는데 이틀이 걸린다면 200개의 서로 다른 하이퍼 매개변수 조합 중 최적을 선택하는 작업은 1년 이상 걸리지만 GPU를 사용하면 일주일 이내에 마칠 수 있음

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 요인
 - 인터넷의 발달로 학습 데이터가 크게 증가
 - 예를 들어, ImageNet은 인터넷에서 수집한 1400만 장 정도의 자연 영상을 카테고리 별로 분류해 제공함
 - 게다가, 데이터에 가우시안 잡음을 섞거나 영상을 조금 이동하거나 회전해 데이터를 인위적으로 수십~수백 배 증가시키는 기법이 개발되었음




그림 5-2 자연 영상의 심한 변화 예(ImageNet의 고양이 부류 사진)

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 요인

- 인터넷의 발달로 학습 데이터가 크게 증가. (완전 다른 이야기! 최근 트렌드)

Generative Data Refinement (GDR) : 제안자→Google DeepMind 연구진 (2025년 초 공개)

- 문제정의:

- LLM 학습용 데이터가 점점 고갈됨 → 더 이상 “새로운 인간 생성 텍스트” 확보가 어렵다.
- 기존에 수집된 대규모 데이터 중 상당수는 부적합 (toxicity, privacy violation, fact error, 품질 저하 등) 때문에 학습에서 제외하고 있었음.
- 결과적으로 usable 데이터 풀(pool)이 급속히 줄어들음.

- 아이디어:

- 기존 unusable 데이터를 generative 모델로 다시 쓰게 함
- 단순히 필터링으로 버리는 대신, 생성형 모델을 활용해 문장을 고쳐서 유해성/오류를 줄이고 학습 가능한 high-quality 데이터로 변환.
- 예시: 욕설이나 개인정보가 들어간 문장을 “깨끗한 표현”으로 재작성, fact error를 제거하거나 부드러운 표현으로 바꾸기.

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 요인
 - 학습을 효과적으로 실행할 수 있는 다양한 알고리즘 개발
 - 계산은 단순하고 성능은 더 좋은 활성화 함수^{activation function} 를 발견
 - 특히 ReLU의 발견으로 모델의 그래디언트 소멸 문제가 크게 완화되었음
 - 학습에 효과적인 다양한 규제 기법^{regularization} 이 개발되었음
 - 가중치를 작은 값으로 유지하는 가중치 축소^{weight decay} 기법
 - 임의로 일정 비율의 노드를 선택해 불능으로 놓고 학습하는 드롭아웃^{dropout} 기법
 - 조기 멈춤, 데이터 확대, 앙상블 등의 다양한 규제 기법이 개발되었음
 - 다양한 손실 함수와 최적화 알고리즘^{optimizer} 개발도 성능 향상에 크게 기여하였음

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 사례 (학술적인 측면)
 - **컨볼루션 신경망(CNN)이 딥러닝의 가능성을 열었음**
 - 컨볼루션 신경망은 특징 추출에 적합한 작은 크기의 컨볼루션 마스크를 사용하기 때문에 완전연결 구조인 다층 퍼셉트론 보다 매개변수가 훨씬 적지만 훨씬 우수한 특징을 추출함
 - 이런 이유로 컨볼루션 신경망에서 우수한 성능이 가장 먼저 입증되었음
 - 1990년대에 뉴욕 대학교의 리쿤 교수는 CNN으로 필기 숫자 인식에서 획기적인 성능 향상을 얻었고, 이 기술혁신으로 필기 숫자 인식이 수표 인식에서 실용화 수준에 도달하게 됨(1998)
 - 이후 CNN에서 개발된 여러 기법은 딥러닝 전반에 큰 영향을 미침

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 사례 (학술적인 측면)
 - **컨볼루션 신경망(CNN)이 딥러닝의 가능성을 열었음**
 - 르쿤이 필기 숫자에서 CNN의 가능성을 보였음에도 불구하고 자연 영상에 대한 시도는 소극적이었음
 - 2012년 ILSVRC 에서 CNN을 사용한 AlexNet이 오류율 15.3%라는 경이로운 성능으로 우승함. 전년도에 고전적인 기계 학습을 사용한 팀이 오류율 25.8%로 우승한 사실을 감안하면 CNN의 가능성을 보여주기에 충분함
 - 이때부터 컴퓨터 비전 연구는 고전적인 기법에서 딥러닝으로 패러다임 전환이 이루어짐
 - **딥러닝은 음성인식 분야의 혁신을 가져옴**
 - 딥러닝 이전에는 음성 인식을 주로 통계적 기법과 HMM^{Hidden Markov Model}을 이용해 구현하였음
 - 2009년경에 토론토 대학교의 힌튼 교수 연구팀은 음성 인식에 딥러닝을 적용하기 시작함
 - 힌튼 교수는 안드로이드 운영체제에 들어가는 음성 인식 소프트웨어의 단어 인식 오류율을 단숨에 25%나 줄였음

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 사례 (학술적인 측면)
 - Transformer 를 통한 LLM 시대 개막

항목	CNN	Transformer
시기	2012 (AlexNet)	2017 (Attention is All You Need)
혁신 포인트	이미지에서 feature learning 혁신	순차 데이터 처리 혁신 (RNN 종식)
상징적 의미	딥러닝이 기존 패러다임을 압도	Foundation Model·LLM 시대 개막
파급력	CV 전분야 표준화	NLP → CV/ 멀티모달 → 로봇틱스까지 확장

5.1.1 딥러닝의 기술 혁신

- 딥러닝의 기술 혁신 사례 (학술적인 측면)
 - ViT (Vision Transformer)는 컴퓨터 비전의 Foundation Model 시대의 문을 열었음

항목	CNN (2012 이후)	ViT (2020 이후)
혁신 포인트	딥러닝이 전통 기법을 압도함	CV에서도 Transformer가 가능함을 입증
효과	“딥러닝 시대” 개막	“모달리티 융합 시대” 가속
파급력	이미지 분류·검출· 세그멘테이션의 표준	멀티모달 학습·VLM· Foundation Model 표준

5.1.2 딥러닝 소프트웨어

- 여러 대학과 기업은 딥러닝 소프트웨어를 개발해 내부 연구 그룹끼리 공유하기 시작함
- 공유를 통해 딥러닝 소프트웨어는 점점 개선되어 큰 규모로 발전했고, 개발자들은 누구나 사용할 수 있도록 라이브러리 형태로 제작해 경쟁적으로 공개함
- 딥러닝 소프트웨어 자체는 대부분 C와 C++ 로 개발하지만, 소프트웨어를 불러 쓰는 인터페이스 언어로는 파이썬과 같은 스크립트 언어를 채택함

5.1.2 딥러닝 소프트웨어

표 5-1 딥러닝 소프트웨어

이름	개발 그룹	최초 공개일	작성 언어	인터페이스 언어	전이학습 지원	철저한 관리
씨아노(Theano)	몬트리올 대학교	2007년	파이썬	파이썬	○	X
카페(Caffe)	UC버클리	2013년	C++	파이썬, 매트랩, C++	○	X
텐서플로 (TensorFlow)	구글 브레인	2015년	C++, 파이썬, CUDA	파이썬, C++, 자바, 자바스크립트, R, Julia, Swift, Go	○	○
케라스(Keras)	프랑소와 솔레 (François Chollet)	2015년	파이썬	파이썬, R	○	○
파이토치(PyTorch)	페이스북	2016년	C++, 파이썬, CUDA	파이썬, C++	○	○

5.1.2 딥러닝 소프트웨어

- 구글 트렌드를 통해 텐서플로우와 파이토치의 최근 영향력을 비교한 그래프를 살펴보면, 2020년 12월 기준으로 둘의 영향력은 막상막하로 보임




그림 5-3 구글 트렌드를 통해 비교한 텐서플로우와 파이토치의 영향력

5.1.2 딥러닝 소프트웨어

요약 타임라인

2008 - 2013: Theano, Caffe → 초기 연구자용 툴

2013 - 2016: Torch, Chainer → 동적 그래프 개념 도입

2015 - 2018: TensorFlow, PyTorch, MXNet → 양강 체제, 산업 vs 연구

2019 - 2022: PyTorch 사실상 표준, Hugging Face 허브 확산

2023 - Now: JAX, DeepSpeed, Megatron 등 초거대 모델·효율 중심

■ 통합기 (2019~2022): PyTorch 사실상 표준화

- PyTorch가 연구·산업계 모두에서 주도적 위치 확보.
- TensorFlow는 2.x로 전환하며 “Eager Execution” 추가 → PyTorch 스타일 따라감.
- ONNX (Open Neural Network Exchange, 2017~) → 프레임워크 간 호환성 표준.
- 특징: PyTorch 생태계 중심으로 연구자 커뮤니티 통합, 오픈소스 모델 허브(Hugging Face)가 폭발적으로 성장

5.1.2 딥러닝 소프트웨어

요약 타임라인

2008 - 2013: Theano, Caffe → 초기 연구자용 툴

2013 - 2016: Torch, Chainer → 동적 그래프 개념 도입

2015 - 2018: TensorFlow, PyTorch, MXNet → 양강 체제, 산업 vs 연구

2019 - 2022: PyTorch 사실상 표준, Hugging Face 허브 확산

2023 - Now: JAX, DeepSpeed, Megatron 등 초거대 모델·효율 중심

- 최신 동향 (2023~현재): Foundation Model & 효율 중심
 - **특징: 단순 프레임워크 경쟁 → 초대규모 모델 학습 생태계로 확장.**
 - JAX (Google, 2018~)
 - NumPy 호환 + XLA 컴파일 최적화.
 - Flax, Haiku 같은 딥러닝 라이브러리 등장.
 - TPU·대규모 모델 연구에서 각광.
 - DeepSpeed (Microsoft, 2020~)
 - 초거대 모델 학습 최적화 (ZeRO optimizer 등).
 - Megatron-LM (NVIDIA, 2019~)
 - GPT 계열 대규모 모델 학습용 프레임워크.

5.2 파이토치 개념 익히기

- 본 강의에서는 인공지능을 구현하기 위해 파이토치 라이브러리를 사용함
- 본 강의의 실험을 위해 파이토치를 자신의 컴퓨터에 직접 설치할 수 있으나, 본 강의에서는 환경 설정이 완료된 <캐글 노트북>을 사용할 예정임
- 즉, 개인 컴퓨터에 파이토치를 직접 설치하는 방법은 본 강의에서 다루지 않음

5.2 파이토치 개념 익히기

5.2.1 파이토치와 넘파이 호환

[프로그램 5-1] 파이토치 버전과 동작 확인

[2]:

```
1 import torch
```

```
2
```

```
3 print(torch.__version__)
```

03행 torch version 확인

```
4 a = torch.rand(2,3)
```

```
5 print(a)
```

```
6 print(type(a))
```

04행 0~1사이의 값을 가지는 난수를 원하는 크기에 해당하는 Tensor 반환



```
2.6.0+cu124
```

```
tensor([[0.5793, 0.0645, 0.8477],  
        [0.2953, 0.2734, 0.5942]])
```

```
<class 'torch.Tensor'>
```

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p1-codingnote>

5.2 파이토치 개념 익히기

5.2.1 파이토치와 넘파이이 호환

[프로그램 5-2] pytorch 텐서와 numpy 텐서의 호환 (사칙연산 가능)

▷

```
1 import torch
2 import numpy as np
3
4 t = torch.rand(2,3)
5 print('pytorch로 생성한 텐서 : \n {}'.format(t))
6 |
7 n = np.random.uniform(size=(2,3))
8 print('pytorch로 생성한 텐서 : \n {}'.format(n))
9
10 # pytorch 텐서와 numpy 텐서는 상호 호환이 가능함
11 res = t + n
12 print('\n덧셈 결과 : \n {}'.format(res))
13
```

04행 0~1사이의 값을 가지는 난수를 원하는 크기에 해당하는 Tensor 반환

07행 low~high사이의 랜덤 난수를 생성하여 원하는 사이즈의 ndarray 반환

pytorch로 생성한 텐서 :

```
tensor([[0.5047, 0.4212, 0.9179],
        [0.1722, 0.0924, 0.1931]])
```

pytorch로 생성한 텐서 :

```
[[0.0992473  0.03076871 0.48778488]
 [0.86071889 0.50314445 0.35460127]]
```

덧셈 결과 :

```
tensor([[0.6040, 0.4520, 1.4057],
        [1.0329, 0.5956, 0.5477]], dtype=torch.float64)
```

+ Code

+ Markdown

5.2 파이토치 개념 익히기

5.2.2 텐서 이해하기

[프로그램 5-3] pytorch가 제공하는 데이터셋의 텐서 구조 확인하기

▷

```
1 import torch
2 from torchvision import datasets
3 from torchvision.transforms import ToTensor
4
5 MNIST_training_data = datasets.MNIST(
6     root='data',|
7     train=True,
8     download=True,
9     transform=ToTensor()
10 )
11
12 MNIST_test_data = datasets.MNIST(
13     root='data',
14     train=False,
15     download=True,
16     transform=ToTensor()
17 )
18
19 print("MNIST 학습 이미지 데이터 텐서 모양 : {}".format(MNIST_training_data[0][0].shape))
20 print("MNIST 학습 라벨 데이터 : {}".format(MNIST_training_data[0][1]))
21
22 print("MNIST 테스트 이미지 데이터 텐서 모양 : {}".format(MNIST_test_data[0][0].shape))
23 print("MNIST 테스트 라벨 데이터 : {}".format(MNIST_test_data[0][1]))
```

06행 root : data를 다운 받을 root 경로

07행 train : Train data를 받을지 말지 (True/False)

08행 download : 직접 다운로드 하여 root 경로에 저장할지 말지 (True/False)

09행 transform : 데이터를 불러올 때 어떤 변환을 적용할 지

```
MNIST 학습 이미지 데이터 텐서 모양 : torch.Size([1, 28, 28])
MNIST 학습 라벨 데이터 : 5
MNIST 테스트 이미지 데이터 텐서 모양 : torch.Size([1, 28, 28])
MNIST 테스트 라벨 데이터 : 7
```

5.2 파이토치 개념 익히기

5.2.2 텐서 이해하기

[프로그램 5-3] pytorch가 제공하는 데이터셋의 텐서 구조 확인하기

```
1 import torch
2 from torchvision import datasets
3 from torchvision.transforms import ToTensor
```

[프로그램 5-3] pytorch가 제공하는 데이터셋의 텐서 구조 확인하기

- MNIST_training_data / MNIST_test_data 는 Dataset 객체이고, 인덱스로 접근하면 (image_tensor, label) 형태의 튜플을 반환함
 - MNIST_training_data[0] → (image, label)
 - MNIST_training_data[0][0] → image (텐서)
 - MNIST_training_data[0][1] → label (정답, int)

```
12 MNIST_test_data = datasets.MNIST(
13     root='data'
14 )
15
16 # MNIST 학습 데이터 중 첫번째 데이터와 라벨
17 MNIST_training_data[0][0]
18 MNIST_training_data[0][1]
19
20 # MNIST 학습 데이터 중 마지막 데이터와 라벨
21 MNIST_training_data[60000-1][0]
22 MNIST_training_data[60000-1][1]
```

```
MNIST 학습 이미지 데이터 텐서 모양 : torch.Size([1, 28, 28])
MNIST 학습 라벨 데이터 : 5
MNIST 테스트 이미지 데이터 텐서 모양 : torch.Size([1, 28, 28])
MNIST 테스트 라벨 데이터 : 7
```

5.2 파이토치 개념 익히기

- 튜플 (tuple)의 정의
 - 여러 개의 값을 하나의 묶음으로 저장하는 자료형
 - 리스트(list)와 비슷하지만, 가장 큰 차이는 수정 불가능(immutable)
 - 소괄호 () 를 사용해서 만듦

◆ 기본 예시

python

```
t = (10, 20, 30)
print(t[0]) # 10
print(t[1]) # 20
```

- `t[0]` → 10
- `t[1]` → 20
- 튜플도 인덱스로 접근 가능.

◆ 리스트와의 차이

python

```
# 리스트
l = [1, 2, 3]
l[0] = 100
print(l) # [100, 2, 3] ✅ 수정 가능
```

```
# 튜플
t = (1, 2, 3)
# t[0] = 100 # ❌ 오류 발생 (TypeError)
```

즉, 리스트는 mutable(변경 가능), 튜플은 immutable(변경 불가).

5.2 파이토치 개념 익히기

- 튜플 (tuple) 의 특징
 - 순서가 있다 → 인덱싱, 슬라이싱 가능
 - 중복을 허용한다 → (1, 2, 2, 3) 가능
 - 수정 불가능하다 → 요소 추가, 삭제, 변경 불가
 - 다른 자료형 포함 가능
- 튜플 (tuple) 이 유용한 이유
 - 변하지 않아야 하는 데이터를 표현할 때 안전
 - 딕셔너리의 키로 사용할 수 있음 (리스트는 변경 가능해서 키로 못 씀)
 - 함수에서 여러 값을 한 번에 반환할 때 자주 사용됨

python

```
mixed = (1, "apple", [10,20], (3,4))
```

튜플 안에 리스트, 또 다른 튜플도 포함할 수 있다.

5.2 파이토치 개념 익히기

5.2.2 텐서 이해하기

[프로그램 5-3] pytorch가 제공하는 데이터셋의 텐서 구조 확인하기

- **번외 : ToTensor() 변환이 해주는 일**
 - 데이터 타입 변환
 - PIL Image → PyTorch Tensor
 - dtype: torch.float32
 - 픽셀값 정규화
 - 원래 0~255 → 0.0~1.0 범위로 나눔 (/255)
 - 딥러닝에서 값이 작을수록 학습 안정성 높임 (Gradient 발산 방지)
 - 차원 순서 변경
 - 원래 이미지: (H, W, C)
 - PyTorch Tensor: (C, H, W)
 - 이유: PyTorch CNN 레이어는 (Batch, Channel, Height, Width) 구조를 요구함

5.2 파이토치 개념 익히기


5.2.2 텐서 이해하기

[프로그램 5-3] pytorch가 제공하는 데이터셋의 텐서 구조 확인하기

■ 번외: ToTensor() 변환이 해주는 일

```
> 1 from torchvision import transforms
  2 from PIL import Image
  3 import numpy as np
  4
  5 # 임의의 흑백 이미지 (28x28)
  6 arr = np.random.randint(0, 256, (28,28), dtype=np.uint8)
  7 img = Image.fromarray(arr) # PIL 이미지
  8
  9
 10 # 시각화
 11 import matplotlib.pyplot as plt
 12 plt.imshow(img, cmap="gray")
 13 plt.show()
 14
 15
 16 tensor = transforms.ToTensor()(img)
 17
 18 print("PIL 모드:", type(img), np.array(img).dtype, np.array(img).shape)
 19 print("Tensor 모드:", tensor.shape, tensor.dtype, tensor.min().item(), tensor.max().item())
 20
```

코드 실행 출력



PIL 모드: <class 'PIL.Image.Image'> uint8 (28, 28)
Tensor 모드: torch.Size([1, 28, 28]) torch.float32 0.0 1.0



5.2 파이토치 개념 익히기

5.2.2 텐서 이해하기


[프로그램 5-3] pytorch가 제공하는 데이터셋의 텐서 구조 확인하기

- Datasets객체인스턴스를 인덱싱하여 반환된 튜플은 아래와 같이 사용 가능

```
1 img, label = MNIST_training_data[0]
2
3 # 텐서 모양
4 print(img.shape) # torch.Size([1, 28, 28]) -> 흑백채널, 높이, 너비
5 print(label)     # 정수 (0~9)
6
7 # 시각화
8 import matplotlib.pyplot as plt
9 plt.imshow(img.squeeze(), cmap="gray")
10 plt.title(f"Label: {label}")
11 plt.show()
```

코드 실행 출력

```
torch.Size([1, 28, 28])
5
```



5.3 파이토치 프로그래밍 기초

이제 라이브러리를
파이토치로 바꿔보자

5.3.1 sklearn의 표현력 한계

- 4장에서는 sklearn 라이브러리를 활용해 기계학습 모델을 구현하였음
- MLP를 떠올려보면 **sklearn** 은 딥러닝을 구현하기에는 표현력의 한계가 있음
- 딥러닝 모델은 MLP 처럼 단순하지 않으며, 컨볼루션 연산을 사용하는 “**컨볼루션 신경망**”으로 확장되고, 은닉 노드끼리 에지로 연결되는 “**순환 신경망**”으로 확장되며, 신경망 구조를 벗어난 “**강화학습**”으로 확장됨
- <텐서플로우>나 <파이토치> 같은 라이브러리는 이런 복잡도를 지원할 수 있도록 바닥부터 **새롭게 설계한 딥러닝 전용 소프트웨어**이며, 이들은 명령어로 층을 쌓아가는 방식으로 프로그래밍을 진행함
- 딥러닝 프로그램에도 디자인 패턴이 있고, 디자인 패턴을 따른 좋은 예제 코드가 많으니 이들을 잘 관찰하고 기억하면 어렵지 않게 딥러닝 프로그래밍에 익숙해질 수 있음

sklearn library → pytorch library

5.3 파이토치 프로그래밍 기초

5.3.2 파이토치를 이용한 퍼셉트론 프로그래밍

[프로그램 5-4] 파이토치 프로그래밍 : 학습된 퍼셉트론 동작 (OR Opeation, predefined Weight)

- Pytorch를 이용한 모델 학습법
- Perceptron 추상화

5.3 파이토치 프로그래밍 기초

5.3.2 파이토치를 이용한 퍼셉트론 프로그래밍

[프로그램 5-4] 파이토치 프로그래밍 : 학습된 퍼셉트론 동작 (OR Operation, predefined Weight)

```
1 import torch
2
3 x = torch.tensor([[0.0, 0.0], [0.0, 1.0], [1.0, 0.0], [1.0, 1.0]])
4 y = torch.tensor([-1], [1], [1], [1]])
5
6 w = torch.autograd.Variable(torch.tensor([[1.0], [1.0]]), requires_grad=True)
7 b = torch.autograd.Variable(torch.tensor([-0.5]), requires_grad=True))
8
9 s = x.matmul(w)+b
10 o = torch.sign(s)
11
12 print("[5-4프로그램] \n {}".format(o))
```

06행 gradient 추적을 허용하는 가중치 행렬 W 정의

07행 gradient 추적을 허용하는 편향 b 정의

10행 wx+b 형태로 계산한 다음 결과의 부호만을 반환



[5-4프로그램]

```
tensor([[ -1.],
        [ 1.],
        [ 1.],
        [ 1.]], grad_fn=<SignBackward0>)
```

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p2-codingnote>

5.3 파이토치 프로그래밍 기초

5.3.2 파이토치를 이용한 퍼셉트론 프로그래밍

[프로그램 5-5] 파이토치 프로그래밍 : 퍼셉트론 학습

```
1 import torch
2 def forward(w, b, x):
3     s = x.matmul(w)+b
4     o = torch.tanh(s) #은닉층 활성화함수 - 교재를 따라 tanh
5     return o
6
7 def loss_mes(pred, y):
8     loss = torch.mean((y-pred)**2)
9     return loss
10
11 if __name__ == '__main__':
12     x = torch.tensor([[0.0,0.0],[0.0,1.0],[1.0,0.0],[1.0,1.0]])
13     y = torch.tensor([-1],[1],[1],[1]))
14
15     # 방식1 - 메모리 효율은 낮지만, 가독성 높음 (초보자용)
16     w = torch.tensor((torch.rand(2, 1) - 0.5), requires_grad=True)
17     b = torch.tensor([0.0], requires_grad=True)
18
19     # 방식2 - 메모리 효율 좋지만, 가독성 낮음
20     # w = (torch.rand(2, 1) - 0.5).clone().detach().requires_grad_(True)
21     # b = torch.zeros(1, requires_grad=True)
22
23     optimizer = torch.optim.SGD([w,b], lr=0.1)
24
25     for iter in range(500): # 0~499반복
26         pred = forward(w,b,x)
27         cost = loss_mes(pred, y)
28
29         optimizer.zero_grad()
30         cost.backward()
31         optimizer.step()
32         #print(iter)
33
34     pred = forward(w,b,x)
35     print(pred)
36     print(torch.sign(pred)) #출력층 활성화함수 : 계단함수
```

02행 $wx+b$ 형태로 계산하고 tanh 함수를 적용하여 순방향 연산 진행

07행 예측값과 정답값의 제곱 오차를 계산하는 MSE 손실함수

16-17행 (20-21행) gradient 추적을 허용하는 가중치,편향 정의

23행 확률적 경사하강법(SGD)에 해당하는 옵티마이저 선언(W,b를 최적화)

29행 `optimizer.zero_grad()` : 매 iteration 마다 gradient 초기화

30행 `cost.backward()` : 손실 함수로부터 역전파(backpropagation) 수행

31행 `optimizer.step()` : 역전파로부터 계산된 gradient를 토대로 W,b 업데이트

```
tensor([[ -1.],
        [  1.],
        [  1.],
        [  1.]])
```

5.3 파이토치 프로그래밍 기초

5.3.2 파이토치를 이용한 퍼셉트론 프로그래밍

[프로그램 5-6] 파이토치 프로그래밍 : 퍼셉트론 학습 (추상화)

```
1 import torch
2
3 # 클래스를 이용한 모델 정의, nn.Module 상속 받아 사용
4 class Perceptron(torch.nn.Module):
5     def __init__(self, input_dim, output_dim): #클래스 인스턴스 생성시 호출되는 생성자 개념
6         super(Perceptron, self).__init__()
7         self.Perceptron = torch.nn.Linear(in_features=input_dim,
8                                             out_features=output_dim,
9                                             bias=True)
10        self.activation = torch.nn.Tanh()
11        # 모델 이어 붙이는 부분
12        self.model = torch.nn.Sequential(self.Perceptron, self.activation)
13
14    def forward(self, x):
15        return self.model(x)
16
17
18 def loss_mes(pred, y):
19     loss = torch.mean((y-pred)**2)
20     return loss
21
22 if __name__ == '__main__':
23     x = torch.tensor([[0.0,0.0],[0.0,1.0],[1.0,0.0],[1.0,1.0]])
24     y = torch.tensor([[1],[1],[1],[1]])
25
26     # 파이토치를 이용한 모델 직접 정의
27     Perceptron = Perceptron(input_dim=2, output_dim=1)
28     optimizer = torch.optim.SGD(Perceptron.parameters(), lr=0.1)
29
30     for iter in range(500): # 0~499반복
31
32         pred = Perceptron(x) #pred = Perceptron.forward(x) 무관
33         cost = loss_mes(pred, y)
34
35         optimizer.zero_grad()
36         cost.backward()
37         optimizer.step()
38         #print(iter)
39
40     pred = Perceptron(x) #pred = Perceptron.forward(x) 무관
41
42     print(pred)
43     print(torch.sign(pred))
```

01행 torch.nn.Module을 상속 받는 Class 정의

07행 torch.nn.Linear를 이용하여 선형 모델(퍼셉트론)을 정의

10행 활성화 함수는 torch.nn.Tanh()를 사용

12행 torch.nn.Sequential을 사용하여 모듈을 순차적으로 정의

14행 순전파를 다음과 같이 정의 (torch.nn.Module을 상속 받았기 때문)
Perceptron(x) 처럼 사용가능

35행 optimizer.zero_grad() : 매 iteration마다 gradient 초기화

36행 cost.backward() : 손실 함수로부터 역전파(backpropagation) 수행

37행 optimizer.step() : 역전파로부터 계산된 gradient를 토대로 W,b 업데이트

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

- Torchvision을 이용한 공개 데이터셋 사용법
- 데이터셋 배치 로더 & 배치 단위 학습, 셔플을 통한 랜덤 학습
- MLP 추상화
- GPU 내 CUDA 라이브러리를 통한 모델 학습
- 모델 학습 로그 데이터(loss, accuracy) 시각화

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

- **배치 단위 학습의 장점
 - 계산 효율
 - GPU/CPU 벡터 연산 최적화 → 1개씩 학습보다 훨씬 빠름.
 - 일반화 성능 향상
 - 배치마다 데이터가 조금씩 다르기 때문에, 모델이 특정 샘플에 과적합 방지
 - 안정성과 노이즈 균형
 - 너무 작은 배치 → gradient가 noisy (학습 불안정, 하지만 더 일반화 잘될 수도 있음)
 - 너무 큰 배치 → gradient가 정확하지만, 일반화 성능 떨어지고 메모리 낭비
 - 보통 32~256 사이가 많이 쓰임.

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

- **셔플을 통한 랜덤 학습의 장점
 - 순서 편향 제거
 - 만약 데이터가 (고양이 1000장, 개 1000장) 순으로 정렬되어 있다면, 모델이 초반에는 고양이만 보고 학습해서 불안정함
 - 셔플하면 고양이/개가 고르게 섞여 학습
 - 균일한 학습 보장
 - 모든 배치가 랜덤한 분포를 가지게 되어, 특정 클래스나 패턴이 몰려있는 현상을 방지
 - 일반화 성능 향상
 - 데이터 순서에 과적합되지 않고, 다양한 조합의 샘플을 보며 학습 → 더 강인한 모델 학습

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p3-codingnote/>

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

```
1 import torch
2 import tqdm
3
4 from torchvision import datasets
5 from torchvision.transforms import ToTensor
6 |
7
8 class MultiLayerPerceptron(torch.nn.Module):
9     def __init__(self, input_dim, hidden_dim, output_dim):
10         super(MultiLayerPerceptron, self).__init__() 상속 받은 부모의 init 실행하고, 자식에 추가된 init 실행
11         # MLP 각 레이어 정의
12         self.input_layer = torch.nn.Linear(in_features=input_dim, out_features=hidden_dim, bias=True)
13         self.hidden_layer = torch.nn.Linear(in_features=hidden_dim, out_features=output_dim, bias=True)
14         self.activation = torch.nn.Tanh()
15         # 모델 정의 : 레이어 연결
16         self.model = torch.nn.Sequential(self.input_layer, self.activation, self.hidden_layer)
17
18     def forward(self, x):
19         return self.model(x)
20
```

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p3-codingnote/>

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

```
21 if __name__ == '__main__':
22
23     # 로그용 딕셔너리 정의 → 학습 중간에 정확도와 손실을 기록할 딕셔너리 정의
24     log_dict = dict()
25     log_dict['train_acc'] = list()
26     log_dict['test_acc'] = list()
27     log_dict['train_loss'] = list()
28     log_dict['test_loss'] = list()
29
30     ## 데이터셋 준비 - W5P1에서 배움
31     MNIST_training_data = datasets.MNIST(root='data', train=True, download=True, transform=ToTensor())
32     MNIST_test_data = datasets.MNIST(root='data', train=False, download=True, transform=ToTensor())
33
34     ## 배치 단위 데이터셋 준비 → Iterable 객체 리턴
35     train_dataloader = torch.utils.data.DataLoader(MNIST_training_data, batch_size=128)
36     test_dataloader = torch.utils.data.DataLoader(MNIST_test_data, batch_size=128, shuffle=False)
37
38     # 모델 정의 - W5P2 Perceptron 확장
39     MLP = MultilayerPerceptron(input_dim=784, hidden_dim=1024, output_dim=10)
40     MLP = MLP.cuda()
41     #optimizer = torch.optim.Adam(MLP.parameters(), lr=0.001)
42     optimizer = torch.optim.SGD(MLP.parameters(), lr=0.001)
43     loss_mse = torch.nn.CrossEntropyLoss()
44
45     → 일반적으로 분류 문제에 사용하는 손실함수
```

GPU 연산의 조건

데이터가 cuda에 올라가야 하고,
모델이 cuda에 올라가야 함

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

```
46 # 모델 학습
47 for iter in tqdm.tqdm(range(30)):
48     #MLP, history = train_epoch(train_dataloader, optimizer, MLP, loss_mse, history)
49     acc_train = 0
50     loss_train = 0
51     MLP.train()
52
53     # 학습 데이터 배치단위 로드
54     for X, y in train_dataloader:
55         X = X.view(-1, 784).cuda()
56         y = y.cuda()
57
58         pred = MLP(X)
59         cost = loss_mse(pred, y)
60
61         optimizer.zero_grad()
62         cost.backward()
63         optimizer.step()
64
65         acc_train += torch.sum(torch.argmax(pred, dim=1)==y).item()
66         loss_train += cost.item()
67
68 # 학습 로그 기록
69 log_dict['train_acc'].append(acc_train/len(train_dataloader.dataset))
70 log_dict['train_loss'].append(loss_train)
```

→ tqdm은 파이썬에서 반복문 진행 상황(progress bar)을 쉽게 표시해주는 라이브러리

→ model.train() : 모델을 학습 모드로 변경 (batchnorm이나 dropout 관련)

→ 28x28 크기의 데이터(X)를 784x1 데이터로 reshape & GPU 메모리에 올림

→ 정답 데이터(y)도 GPU 메모리에 올려줌

배치 단위 학습 시작 시
데이터 shuffle 됨
(sampler 사용)

→ optimizer.zero_grad() : 매 iteration마다 gradient 연산 변수 초기화

→ cost.backward() : 손실 함수로부터 역전파(backpropagation) 수행

→ optimizer.step() : 역전파로부터 계산된 gradient를 토대로 W,b 업데이트

nn.Module에서 call 함수로
매핑을 해줘서 자동으로 호출

기울기 초기화 필요 (파이토치가 기울기를 축적하여 사용하다보니..)

역전파 계산

가중치 갱신

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

```
71
72     # 모델 테스트
73     with torch.no_grad():
74         #MLP, history = test_epoch(test_dataloader, optimizer, MLP, loss_mse, history)
75         acc_test = 0
76         loss_test = 0
77         MLP.eval()
78
79     for X, y in test_dataloader: #테스트 데이터 배치단위 받기
80         X = X.view(-1, 784).cuda()
81         y = y.cuda()
82
83         pred = MLP(X)
84         cost = loss_mse(pred,y)
85
86         # 학습 단계가 아니므로, 아래의 단계 생략
87         #optimizer.zero_grad()
88         #cost.backward()
89         #optimizer.step()
90
91         acc_test += torch.sum(torch.argmax(pred, dim=1)==y).item()
92         loss_test += cost.item()
93
94     log_dict['test_acc'].append(acc_test/len(test_dataloader.dataset))
95     log_dict['test_loss'].append(loss_test)
96
```

→ model.eval() : 모델을 평가 모드로 변경 (batchnorm이나 dropout 관련)

→ 28x28 크기의 데이터를 784x1 데이터로 reshape & 동시에 GPU 메모리에 올림

→ 정답 데이터도 GPU 메모리에 올림


예측값과 정답값이 동일한 개수를 카운트하여 저장

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.2 학습 곡선 시각화

[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식

```
1
2 import matplotlib.pyplot as plt
3
4 # 정확도 도식화
5 plt.plot(log_dict['train_acc'])
6 plt.plot(log_dict['test_acc'])
7 plt.title("Model Accuracy")
8 plt.xlabel("Epoch")
9 plt.ylabel("Accuracy")
10 plt.legend(['Train', 'Validation'], loc='upper left')
11 plt.grid()
12 plt.show()
13
14 # 손실 도식화
15 plt.plot(log_dict['train_loss'])
16 plt.plot(log_dict['test_loss'])
17 plt.title("Loss")
18 plt.xlabel("Epoch")
19 plt.ylabel("Loss")
20 plt.legend(['Train', 'Validation'], loc='upper left')
21 plt.grid()
22 plt.show()
```



과적합 발생 여부 확인을 위한 학습 곡선 시각화



5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.1 MNIST 인식

[프로그램 5-7(b)] 다층 퍼셉트론으로 MNIST 인식

“[프로그램 5-7(a)] 다층 퍼셉트론으로 MNIST 인식” 코드를 좀 더 추상화, 일반화 한 코드

- 옵티마이저를 SGD, Adam으로 선택하여 비교하여 시각화



<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p4-codingnote>

5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.3 fashion MNIST 인식

- 파이토치는 필기 숫자 데이터인 MNIST와 아주 비슷한 **fashion MNIST**를 제공함
- 샘플은 28x28 맵으로 표현되며 훈련 집합 60,000개 샘플, 테스트 집합 10,000개 샘플로 구성됨
- 라벨이 {0,1,2,3,4,5,6,7,8,9}에서 {T-shirt, top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, Ankle boot}로 바뀌고 **샘플 영상이 패션 아이템**이라는 점만 다름



5.4 파이토치 다층 퍼셉트론 프로그래밍

5.4.3 fashion MNIST 인식

[프로그램 5-8] 다층 퍼셉트론으로 Fashion MNIST 인식

[프로그램 5-8]은 [프로그램 5-7] 에서 “데이터셋 준비”하는 코드만 변경하면 됨

```
import torch
import tqdm

if __name__ == '__main__':

    history = dict()
    history['train_acc'] = list()
    history['test_acc'] = list()
    history['train_loss'] = list()
    history['test_loss'] = list()

    training_data = datasets.FashionMNIST(
        root="data",
        train=True,
        download=True,
        transform=ToTensor()
    )

    test_data = datasets.FashionMNIST(
        root="data",
        train=False,
        download=True,
        transform=ToTensor()
    )
```

12행 FashionMNIST 학습 데이터 정의

19행 FashionMNIST 평가 데이터 정의

Pytorch 를 이용한 MLP 실습 과제

- 제출 방식 : 이메일로 보고서 제출
 - 마감 : 10월 13일 (월) 23시 59분
 - 이메일 주소 : admin@rcv.sejong.ac.kr
 - 이메일 제목 : [2025-2] [인공지능] 5주차 과제 제출 (학번_이름)
 - 보고서 분량 제한 없음
- [문제1] MNIST
 - MLP+ADAM, MLP+SGD 프로그래밍 실습
 - <https://www.kaggle.com/t/0a25b4716da14e3db417c25439656639>
- [문제2] Fashion MNIST
 - MLP+ADAM, MLP+SGD 프로그래밍 실습
 - <https://www.kaggle.com/t/df906b6f841e4c5d8d4d397669eca9a5>

5.5 깊은 다층 퍼셉트론

- 〈다층 퍼셉트론〉에 은닉층을 더 많이 추가하면 〈깊은 다층 퍼셉트론〉 DMLP: Deep Multi-Layer Perceptron 이 되며, 깊은 다층 퍼셉트론은 은닉층만 추가하면 되기 때문에 가장 쉽게 생각할 수 있는 딥러닝 모델임

5.5 깊은 다층 퍼셉트론

5.5.1 구조와 동작

- 다층 퍼셉트론의 훈련집합 전체에 대한 동작 표현 $\mathbf{O} = \tau_L \left(\cdots \tau_2 \left(\mathbf{U}^2 \tau_1 \left(\mathbf{U}^1 \mathbf{X}^T \right) \right) \right)$ (5.5)
- 은닉층 활성화함수는 ReLU를 주로 사용하고, 출력층 활성화함수는 tanh 시그모이드, 로지스틱 시그모이드, softmax 함수를 주로 사용
- L-1번째 층과 L번째 층을 연결하는 가중치 행렬

$$\mathbf{U}^l = \begin{pmatrix} u_{10}^l & u_{11}^l & \cdots & u_{1n_{l-1}}^l \\ u_{20}^l & u_{21}^l & \cdots & u_{2n_{l-1}}^l \\ \vdots & \vdots & \ddots & \vdots \\ u_{n_l 0}^l & u_{n_l 1}^l & \cdots & u_{n_l n_{l-1}}^l \end{pmatrix}, \quad l = 1, 2, \dots, L \quad (5.1)$$




그림 5-8 깊은 다층 퍼셉트론의 구조

5.5 깊은 다층 퍼셉트론

5.5.1 구조와 동작

- [그림5-8]은 깊은 다층 퍼셉트론의 구조임
- 양 끝에 입력층과 출력층이 있으며 중간에 **L-1개의 은닉층이 있어 총 L개 은닉층 수+출력층의 층이 있음**
- 은닉층이 하나인 다층 퍼셉트론은 L=2인 특수한 경우임
- 입력층 특징 벡터의 요소 개수에 따라 d개 노드를 가지며 출력층은 부류 개수에 따라 c개 노드를 가짐
 - 예를 들어, MNIST 필기 숫자 데이터의 경우 화소를 특징으로 사용한다면 $d=28 \times 28=784$ 이고, $c=10$ 임,
i번째 은닉층의 개수는 프로그래머가 설정하는 하이퍼 매개변수이며 n_i 로 표기함
- 깊은 다층 퍼셉트론은 인접한 두 층의 모든 노드 사이에 에지가 있는 **완전 연결 fc: fully connected 구조임**




그림 5-8 깊은 다층 퍼셉트론의 구조

5.5 깊은 다층 퍼셉트론

5.5.1 구조와 동작

- 깊은 다층 퍼셉트론은 가중치가 많음
 - 가중치가 많으면 1) 계산 시간이 길어지고 2) 과잉 적합이 발생할 가능성도 커짐
 - 위에 제시된 1) 2) 문제가 극복되어야 딥러닝(깊은 신경망 학습)이 성공할 수 있음
 - 1) 시간이 오래 걸리는 계산 문제는 GPU를 사용해 해결이 가능하고, 2) 과잉 적합은 여러가지 규제 기법(Regularization)으로 해결 가능함
-
- MNIST 데이터셋 L=5, 은닉층 노드 개수가 500일 때의 총 가중치를 구해보자.
 - L=5이므로, 은닉층의 개수는 L-1 로 4개임
 - 입력층-은닉층1 : $(784+1)*500$ // +1은 바이어스
 - 은닉층1-은닉층2 : $(500+1)*500*1$
 - 은닉층2-은닉층3 : $(500+1)*500*1$
 - 은닉층3-은닉층4 : $(500+1)*500*1$
 - 은닉층4-출력층 : $(500+1)*10$ // 10개의 클래스
 - 따라서 총 가중치의 수는 1,149,010개임

5.5 깊은 다층 퍼셉트론

5.5.2 오류 역전파 알고리즘

- 깊은 다층 퍼셉트론을 학습하려면 **손실 함수** 정의와 손실 함수의 최저점을 찾는 **최적화 알고리즘**이 필요
- 손실 함수 : 미니 배치 단위(M)로 오차의 평균

$$J(\mathbf{U}^1, \mathbf{U}^2, \dots, \mathbf{U}^L) = \frac{1}{|M|} \sum_{\mathbf{x} \in M} \|\mathbf{y} - \mathbf{o}\|^2 \quad \leftarrow \text{평균제곱오차(MSE, mean squared error)}$$

$$= \frac{1}{|M|} \sum_{\mathbf{x} \in M} \|\mathbf{y} - \tau_L(\dots \tau_2(\mathbf{U}^2 \tau_1(\mathbf{U}^1 \mathbf{x}^T))\|^2 \quad (5.6)$$

$\leftarrow \tau$: 각 층의 활성화함수, $\mathbf{U}$: 각 층의 가중치

- 가중치 갱신 규칙 $\mathbf{U}^l = \mathbf{U}^l + \rho(-\nabla \mathbf{U}^l), l = L, L-1, \dots, 1 \quad (5.7)$





그림 5-9 깊은 다층 퍼셉트론이 사용하는 오류 역전파 알고리즘

5.5 깊은 다층 퍼셉트론

5.5.2 오류 역전파 알고리즘

- [그림5-9]는 다층 퍼셉트론의 학습 절차를 설명
 - 특징 벡터를 입력층에 입력
 - 전방 계산 (forward)
 - 전방 계산으로 얻은 예측 값을 기대 값과 비교해 오차 계산
 - 오차에 따라 $U^L, U^{L-1}, \dots, U^1$ 순으로 가중치 갱신




그림 5-9 깊은 다층 퍼셉트론이 사용하는 오류 역전파 알고리즘

5.5 깊은 다층 퍼셉트론

5.5.3 깊은 다층 퍼셉트론 프로그래밍

[프로그램 5-9] 깊은 다층 퍼셉트론으로 MNIST 인식 (프로그램 5-7 과 나머지 동일)

```
1 import torch
2 import tqdm
3
4 from torchvision import datasets
5 from torchvision.transforms import ToTensor
6
7 class DeepNeuralNetwork(torch.nn.Module):
8     def __init__(self, input_dim, hidden_dim, output_dim):
9         super(DeepNeuralNetwork, self).__init__()
10
11         self.input_layer = torch.nn.Linear(in_features=input_dim, out_features=hidden_dim, bias=True)
12         self.hidden_layer1 = torch.nn.Linear(in_features=hidden_dim, out_features=hidden_dim, bias=True)
13         self.hidden_layer2 = torch.nn.Linear(in_features=hidden_dim, out_features=hidden_dim, bias=True)
14         self.hidden_layer3 = torch.nn.Linear(in_features=hidden_dim, out_features=hidden_dim, bias=True)
15         self.output_layer = torch.nn.Linear(in_features=hidden_dim, out_features=output_dim, bias=True)
16
17         self.activation = torch.nn.Tanh()
18
19         self.model = torch.nn.Sequential(self.input_layer, self.activation,
20                                         self.hidden_layer1, self.activation,
21                                         self.hidden_layer2, self.activation,
22                                         self.hidden_layer3, self.activation,
23                                         self.output_layer, self.activation)
24
25     def forward(self, x):
26         return self.model(x)
```



11~24행 torch.nn.Linear를 이용하여 선형 모델(퍼셉트론)을 여러 개 정의
입력: 784, 은닉층1: 512, 은닉층2: 512, 은닉층3: 512, 은닉층4: 512, 출력층: 10

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p5-codingnote>

5.5 깊은 다층 퍼셉트론

5.5.3 깊은 다층 퍼셉트론 프로그래밍

[프로그램 5-9] 깊은 다층 퍼셉트론으로 MNIST 인식 (프로그램 5-7 과 나머지 동일)



5.5 깊은 다층 퍼셉트론

5.5.3 깊은 다층 퍼셉트론 프로그래밍

[프로그램 5-9] 깊은 다층 퍼셉트론으로 MNIST 인식 : 가중치 초기화 기법 변경

Linear

```
class torch.nn.Linear(in_features, out_features, bias=True, device=None, dtype=None) \[source\]
```

Applies an affine linear transformation to the incoming data: $y = xA^T + b$.

This module supports [TensorFloat32](#).

On certain ROCm devices, when using float16 inputs this module will use [different precision](#) for backward.

Parameters:

- **in_features** (*int*) – size of each input sample
- **out_features** (*int*) – size of each output sample
- **bias** (*bool*) – If set to `False`, the layer will not learn an additive bias. Default: `True`

Shape:

- Input: $(*, H_{in})$ where $*$ means any number of dimensions including none and $H_{in} = \text{in_features}$.
- Output: $(*, H_{out})$ where all but the last dimension are the same shape as the input and $H_{out} = \text{out_features}$.

Variables:

- **weight** (*torch.Tensor*) – the learnable weights of the module of shape $(\text{out_features}, \text{in_features})$. The values are initialized from $\mathcal{U}(-\sqrt{k}, \sqrt{k})$, where $k = \frac{1}{\text{in_features}}$
- **bias** – the learnable bias of the module of shape (out_features) . If `bias` is `True`, the values are initialized from $\mathcal{U}(-\sqrt{k}, \sqrt{k})$ where $k = \frac{1}{\text{in_features}}$

torch.nn.Linear는 기본적으로 Kaiming Uniform 방식으로 초기화 됨

◆ PyTorch nn.Linear 기본 가중치 초기화

- 가중치(weight)
 - Kaiming Uniform (a.k.a. He Uniform) 방식으로 초기화
 - 논문: He et al. (2015), ReLU 계열 활성화 함수에 적합
 - 수식:

$$\text{bound} = \frac{1}{\sqrt{\text{fan_in}}}$$

그리고 가중치를 $\mathcal{U}(-\text{bound}, \text{bound})$ 에서 샘플링합니다.
(fan_in = 입력 뉴런 수)

- 편향(bias)
 - $\text{Uniform}(-\text{bound}, \text{bound})$ 분포에서 초기화
 - 여기서 $\text{bound} = 1/\sqrt{\text{fan_in}}$

5.5 깊은 다층 퍼셉트론

5.5.3 깊은 다층 퍼셉트론 프로그래밍

[프로그램 5-9] 깊은 다층 퍼셉트론으로 MNIST 인식 : 가중치 초기화 기법 변경

3. 자주 쓰이는 초기화 함수 (torch.nn.init)

- `init.xavier_uniform_(tensor)`
- `init.xavier_normal_(tensor)`
- `init.kaiming_uniform_(tensor, nonlinearity='relu')`
- `init.kaiming_normal_(tensor, nonlinearity='relu')`
- `init.uniform_(tensor, a=0, b=1)`
- `init.normal_(tensor, mean=0, std=1)`
- `init.zeros_(tensor)`
- `init.ones_(tensor)`

초기화 방식	분포	범위/표준편차
Xavier Uniform	균등분포 $U(-a, a)$	$a = \sqrt{\frac{6}{fan_in + fan_out}}$
Xavier Normal	정규분포 $\mathcal{N}(0, \sigma^2)$	$\sigma^2 = \frac{2}{fan_in + fan_out}$

- Uniform: 값들이 일정 범위 내에 고르게 퍼져 있어서 극단적인 큰 값이 잘 안 나옴
- Normal: 중심(0 근처)에 값이 몰리지만, 꼬리에서 극단적인 값이 나올 확률이 있음

5.5 깊은 다층 퍼셉트론

5.5.3 깊은 다층 퍼셉트론 프로그래밍

[프로그램 5-9] 깊은 다층 퍼셉트론으로 MNIST 인식 : 가중치 초기화 기법 변경

```
1 import torch
2 import tqdm
3
4 from torchvision import datasets
5 from torchvision.transforms import ToTensor
6 import torch.nn.init as init
7
8 class DeepNeuralNetwork(torch.nn.Module):
9     def __init__(self, input_dim, hidden_dim, output_dim):
10         super(DeepNeuralNetwork, self).__init__()
11
12         self.input_layer = torch.nn.Linear(in_features=input_dim, out_features=hidden_dim, bias=True)
13         self.hidden_layer1 = torch.nn.Linear(in_features=hidden_dim, out_features=hidden_dim, bias=True)
14         self.hidden_layer2 = torch.nn.Linear(in_features=hidden_dim, out_features=hidden_dim, bias=True)
15         self.hidden_layer3 = torch.nn.Linear(in_features=hidden_dim, out_features=hidden_dim, bias=True)
16         self.output_layer = torch.nn.Linear(in_features=hidden_dim, out_features=output_dim, bias=True)
17
18         self.activation = torch.nn.Tanh()
19
20         self.model = torch.nn.Sequential(self.input_layer, self.activation,
21                                           self.hidden_layer1, self.activation,
22                                           self.hidden_layer2, self.activation,
23                                           self.hidden_layer3, self.activation,
24                                           self.output_layer)
25
26         # Xavier Uniform 초기화 적용
27         self.apply(self._init_weights)
28
29     def _init_weights(self, m):
30         if isinstance(m, torch.nn.Linear):
31             init.xavier_uniform_(m.weight)
32             if m.bias is not None:
33                 init.zeros_(m.bias)
34
35     def forward(self, x):
36         return self.model(x)
```

6행 torch 내 초기화 모듈 사용 정의

24행 모델 마지막에 softmax 추가 하지 않도록 주의
파이토치 CE Loss 에는 이미 softmax가 추가되어 있음

28행 가중치 초기화 함수 호출



30-34행 가중치 Xavier Uniform 방식으로 초기화

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p6-codingnote>

5.5 깊은 다층 퍼셉트론

5.5.3 깊은 다층 퍼셉트론 프로그래밍

[프로그램 5-9] 깊은 다층 퍼셉트론으로 MNIST 인식 : 가중치 초기화 기법 변경 (xavier_uniform)



5.6 딥러닝 학습 전략

5.6.1 그레디언트 소멸 문제와 해결책

- 미분 이론의 연쇄 법칙(chain rule)에 따르면,

[그림5-9]에서 (l)번째 층의 그레디언트는

오른쪽에 있는 (l+1)번째 층의 그레디언트에

자신의 층에서 발생한 그레디언트(미분값)를 곱하여 구함




그림 5-9 깊은 다층 퍼셉트론이 사용하는 오류 역전파 알고리즘

손실 L 에 대해 i 번째 층의 출력 $h^{(i)}$ 의 그레디언트는

$$\frac{\partial L}{\partial h^{(i)}} = \frac{\partial L}{\partial h^{(i+1)}} \cdot \frac{\partial h^{(i+1)}}{\partial h^{(i)}}$$

즉, i 번째 층의 그레디언트는 오른쪽($i+1$ 번째) 층의 그레디언트에, $i+1$ 번째 층에서 i 번째 층으로 가는 도함수를 곱한 것이 맞습니다 ✓

5.6 딥러닝 학습 전략

5.6.1 그레디언트 소멸 문제와 해결책

- 그레디언트가 작으면, (오른쪽에서 왼쪽으로) 가중치 업데이트가 진행하면서 그레디언트가 점점 작아지는 현상 gradient vanishing 이 발생
 - 예를 들어, 깊이가 10이고 모든 층의 그레디언트가 0.01이라고 가정
 - 열 번째 층의 그레디언트는 0.01
 - 아홉 번째 층의 그레디언트는 $0.01 * 0.01 = 0.0001$
 - 여덟 번째 층의 그레디언트는 $0.0001 * 0.01 = 0.000001$
- ➔ 왼쪽으로 진행될 수록 그레디언트가 기하급수적으로 작아짐





그림 5-9 깊은 다층 퍼셉트론이 사용하는 오류 역전파 알고리즘

결국, 그레디언트 소멸 문제가 발생하면 신경망 학습이 느려지고, 학습해도 수렴에 도달하지 못하는 문제가 발생함!

5.6 딥러닝 학습 전략


5.6.1.2 좋은 활성화함수 사용으로 그레디언트 소멸문제 해결

- 그레디언트 소멸 문제는 시그모이드 함수에서 더욱 심함
 - 즉, 가중치 곱의 결과가 크면, 미분 값은 매우 작음
 - (x축) $S=5$ 이면 시그모이드의 그레디언트는 0에 가까움 (정확하게는 0.0000004501)



(a) tanh 시그모이드와 그레디언트

- ReLU 함수는 시그모이드 함수의 문제점을 해소해 줌
 - ReLU는 s 가 양수일 때 그레디언트가 1이고, 음수일 때 0임



(b) ReLU와 그레디언트

5.6 딥러닝 학습 전략

5.6.2 과잉 적합과 과소 적합 회피 전략

- 과소 적합과 과잉 적합
 - 데이터에 비해 작은 용량의 모델을 사용해 오차가 많아지는 현상을 **과소 적합(underfitting)**이라고 함
 - 맨 왼쪽은 1차 방정식을 모델로 채택한 경우이며, 훈련데이터를 제대로 모델링하기에는 용량이 작다 (가중치의 수가 작은 모델)는 사실을 쉽게 알 수 있음
 - 과소 적합을 해소하려면 모델의 용량을 크게 하면 됨 (가중치가 많은 큰 모델 사용)**
 - 아래의 그림은 용량이 큰 모델인 2차, 3차, 12차 방정식을 모델로 사용한 경우의 예시




그림 5-12 과소 적합과 과잉 적합

5.6 딥러닝 학습 전략

5.6.2 과잉 적합과 과잉 적합 회피 전략

- 과소 적합과 과잉 적합
 - 〈너무 큰 모델〉이 데이터에 과도하게 적응하여 일반화 능력을 잃는 현상을 **과잉 적합 overfitting**이라 부름
 - 기계 학습의 최종 목적은 일반화 능력을 최대화 하는 것. 즉, 새로운 샘플에 대해 높은 정확률을 확보하는 것
 - 그런데, 빨간 점으로 표시된 예측 값이 파란 점으로 표시된 참값을 크게 벗어나는 결과를 보이고 있으며, 이는 **모델의 용량이 데이터 복잡도에 비해 너무 커서 발생함 (가중치가 적은 작은 모델 사용)**
 - [그림 5-13]은 x_0 라는 새로운 샘플에 대해 **12차 모델**이 예측한 결과를 보여줌




그림 5-13 과잉 적합에 따른 부정확한 예측

5.6 딥러닝 학습 전략

5.6.2 과잉 적합과 과잉 적합 회피 전략

- 과소 적합과 과잉 적합
 - 너무 큰 모델이 데이터에 과도하게 적응하여 일반화 능력을 잃는 현상을 **과잉 적합 overfitting** 이라 부름
- 과잉 적합을 해소하는 전략은 아주 많은데, 그중 가장 확실한 방법은 데이터의 양을 늘리는 것**




그림 5-14 데이터 양을 늘려 과잉 적합을 해소

5.6 딥러닝 학습 전략

5.6.2 과잉 적합과 과잉 적합 회피 전략

- 과소 적합과 과잉 적합
 - 너무 큰 모델이 데이터에 과도하게 적응하여 일반화 능력을 잃는 현상을 **과잉 적합 overfitting**이라 부름
 - **딥러닝은 큰 용량의 모델을 사용하되 적절한 규제 기법을 적용해 과잉 적합을 피하는 전략을 구사함**
 - 딥러닝에서 사용하는 규제 기법은 데이터의 양을 늘리는 것 외에 조기 멈춤, 가중치 감쇠, 드롭아웃, 앙상블 등이 있음 (6장에서 다룰 예정)

5.7 딥러닝이 사용하는 손실 함수

5.7.1 평균제곱오차 (MSE, mean squared error)

- 통계학에서 아주 오래 전부터 사용된 대표적인 손실 함수로서 신경망이 빌려 쓰는 것
 - 신경망은 여러 개의 샘플로 구성된 미니배치 단위로 손실 함수를 정의하며, 식(5.8)을 미니 배치 단위에 적용하고 평균을 취한 값이 평균제곱오차(MSE, mean squared error)에 해당 됨

$$e = \| \mathbf{y} - \mathbf{o} \|^2 \quad (5.8)$$

$$\begin{aligned} J(\mathbf{U}^1, \mathbf{U}^2, \dots, \mathbf{U}^L) &= \frac{1}{|M|} \sum_{\mathbf{x} \in M} \| \mathbf{y} - \mathbf{o} \|^2 \\ &= \frac{1}{|M|} \sum_{\mathbf{x} \in M} \| \mathbf{y} - \tau_L \left(\dots \tau_2 \left(\mathbf{U}^2 \tau_1 \left(\mathbf{U}^1 \mathbf{x}^T \right) \right) \right) \|^2 \end{aligned} \quad (5.6)$$

- 평균제곱오차의 문제점
 - 오차 e 가 더 큰데 그레디언트가 더 작은 상황이 발생하기도 함
 - 이는 공부를 못하는 학생이 더 높은 점수를 받는 상황(학습 의욕 저하)과 비슷하며, 학습이 느려지거나 학습이 안되는 상황을 초래할 가능성이 높음

5.7 딥러닝이 사용하는 손실 함수

5.7.2 교차 엔트로피

- 교차 엔트로피는 두 확률 분포가 다른 정도를 측정
- 즉, “정답 분포 P”와 “모델이 예측한 분포 Q” 사이의 차이를 재는 손실
- 교차 엔트로피 예시
 - 공정한 주사위 2개가 있을 때, **둘의 확률 분포가 같으므로 교차 엔트로피가 작음**
- 교차 엔트로피 식

$$H(P, Q) = -\sum_{i=1,k} P(e_i) \log Q(e_i) \quad (5.10)$$

공정한 주사위 P와 Q의 교차 엔트로피 (모두 1/6)

$$-\left(\frac{1}{6} \log \frac{1}{6} + \dots + \frac{1}{6} \log \frac{1}{6}\right) = 1.7918$$

공정한 주사위 P와 찌그러진 주사위 Q(숫자 1 이 1/2, 나머지 숫자는 1/10확률)의 교차 엔트로피

$$-\left(\frac{1}{6} \log \frac{1}{2} + \frac{1}{6} \log \frac{1}{10} + \dots + \frac{1}{6} \log \frac{1}{10}\right) = 2.0343$$

5.7 딥러닝이 사용하는 손실 함수

5.7.2 교차 엔트로피 손실 함수

- 딥러닝은 주로 교차 엔트로피를 사용

교차 엔트로피 손실 함수: $e = -\sum_{i=1,c} y_i \log o_i$ (5.11)

[예제 5-1] 교차 엔트로피의 합리성 확인

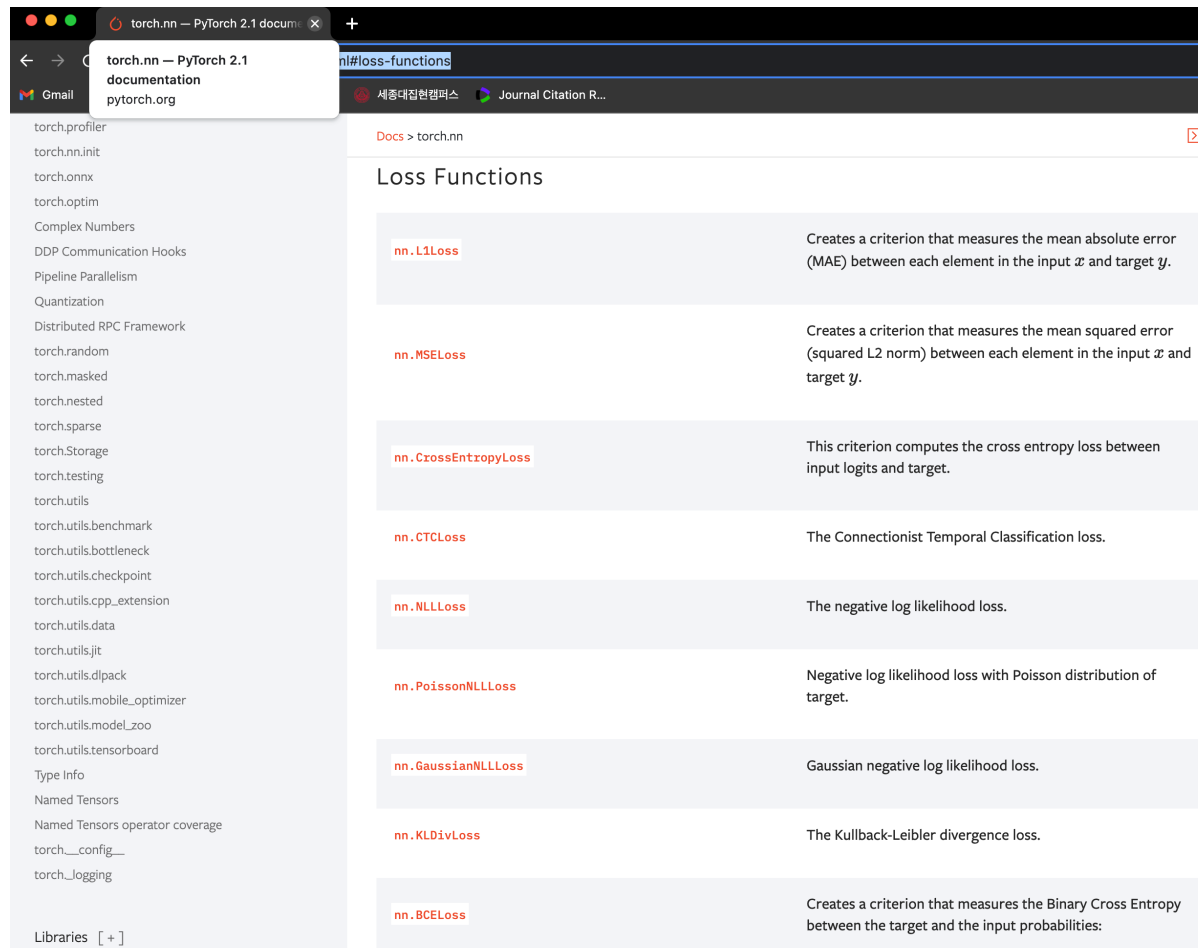
숫자 인식에서 부류 3에 속하는 샘플의 경우 $y=(0,0,0,1,0,\dots,0)$ 이다. 신경망의 출력이 $o=(0.1,0,0,0.9,0,\dots,0)$ 이라 하자. 부류 3에 해당하는 곳이 0.9로서 가장 크므로 신경망이 샘플을 맞힌 경우이다. 식 (5.11)을 계산하면 $e=-(0 \times \log(0.1)+0 \times \log(0)+0 \times \log(0)+1 \times \log(0.9)+\dots+0 \times \log(0))=0.1054$ 가 된다.

이제 신경망이 $o=(0,0.9,0,0.1,0,\dots,0)$ 을 출력했다고 가정하자. 부류 1에 해당하는 곳이 가장 큰 값을 갖기 때문에 신경망이 틀린 경우이다. 이 경우 $e=-(0 \times \log(0)+0 \times \log(0.9)+0 \times \log(0)+1 \times \log(0.1)+\dots+0 \times \log(0))=2.3026$ 이 된다. 후자의 틀린 경우에서 손실 함수 값이 훨씬 큰 사실을 확인할 수 있다.

5.7 딥러닝이 사용하는 손실 함수

5.7.3 손실 함수의 성능 비교 실험

- 파이토치에서 지원하는 손실함수는 아래와 같이 확인 가능
 - <https://pytorch.org/docs/stable/nn.html#loss-functions>



5.7 딥러닝이 사용하는 손실 함수

5.7.3 손실 함수의 성능 비교 실험 (MNIST)

[프로그램5-10] 손실 함수의 성능 비교: 평균제곱오차와 교차 엔트로피

****Torch.nn.MSELoss()의 정답 라벨은 one-hot 형태로 입력되어야 함**

```
44 def train_epoch(train_dataloader, optimizer, model, loss_fn, log_dict, loss_type):
45     acc_train = 0
46     loss_train = 0
47     model.train()
48
49     for X, y in train_dataloader: #학습 데이터 배치단위 로드
50         X = X.view(-1, 784).cuda()
51         y = y.cuda()
52
53         pred = model(X)          # 모델 forward
54
55         target = y if loss_type == "ce" else F.one_hot(y, num_classes=10).float()
56         cost = loss_fn(pred, target) # 손실함수 계산
57
128
129 # 손실함수 비교 실험을 위한 정의
130 loss_mse = torch.nn.MSELoss()
131 loss_ce = torch.nn.CrossEntropyLoss()
132
133
134 # 모델 학습
135 for iter in tqdm.tqdm(range(30)):
136     DNN_adam, log_ce = train_epoch(train_dataloader, optimizer_adam, DNN_adam, loss_ce, log_ce, "ce")
137     # 모델 테스트
138     with torch.no_grad():
139         DNN_adam, log_ce = test_epoch(test_dataloader, optimizer_adam, DNN_adam, loss_ce, log_ce, "ce")
140
141 # 모델 학습
142 for iter in tqdm.tqdm(range(30)):
143     DNN_adam, log_mse = train_epoch(train_dataloader, optimizer_adam, DNN_adam, loss_mse, log_mse, "mse")
144     # 모델 테스트
145     with torch.no_grad():
146         DNN_adam, log_mse = test_epoch(test_dataloader, optimizer_adam, DNN_adam, loss_mse, log_mse, "mse")
147
148
```



<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p7-codingnote>

5.7 딥러닝이 사용하는 손실 함수

5.7.3 손실 함수의 성능 비교 실험 (MNIST)

[프로그램5-10] 손실 함수의 성능 비교: 평균제곱오차와 교차 엔트로피

****Torch.nn.MSELoss()의 정답 라벨은 one-hot 형태로 입력되어야 함**



5.8 딥러닝이 사용하는 옵티마이저

- 신경망 학습은 손실 함수의 최저점을 찾아가는 과정
- 최저점을 찾는 문제는 전형적인 최적화 문제
- 신경망에서 SGD와 같은 최적화 알고리즘을 옵티마이저 optimizer 라고 부름
- 신경망 학습에 이용되는 데이터는 잡음과 변화가 아주 심하여

SGD 옵티마이저가 종종 한계를 드러내며,

이런 한계 극복을 위해 **모멘텀 momentum**과 **적응적 학습률 adaptive learning rate**이라는 방법이 소개됨


5.8 딥러닝이 사용하는 옵티마이저

5.8.1 모멘텀 momentum 을 적용한 옵티마이저

- 물리에서 모멘텀은 이전 운동량을 현재에 반영하는 아이디어를 뜻하며 관성과 관련이 깊음
- 모멘텀을 신경망에 적용하면 성능 향상이 뚜렷하게 나타남

5.8.1.1 모멘텀

- 검은색 실선 : 이전 미니배치에서 누적된 <방향 벡터gradient> v
- 검은 점: 현재 가중치 벡터 w
- 빨간 실선 : 현재 가중치 w 를 현재 미니배치에서 계산된 방향 벡터를 고려하여 빨간 점으로 이동
→ 고전적인 SGD
- 파란 실선 : 현재 가중치 w 를 현재 미니배치에서 계산된 방향 벡터와 이전 미니배치에서 누적된 방향 벡터를 함께 고려하여 파란 점으로 이동 → 모멘텀을 적용한 SGD




5.8 딥러닝이 사용하는 옵티마이저

5.8.1.1 모멘텀

$$\text{고전적 SGD: } \mathbf{w} = \mathbf{w} - \rho \frac{\partial J}{\partial \mathbf{w}}$$

$$\text{모멘텀을 적용한 SGD: } \mathbf{v} = \alpha \mathbf{v} - \rho \frac{\partial J}{\partial \mathbf{w}}$$
$$\mathbf{w} = \mathbf{w} + \mathbf{v}$$

이전 미니배치의 누적된 방향 벡터



- $\alpha=0$ 는 고전적 SGD, 모멘텀을 적용한 SGD α 는 $[0,1]$ 사이에서 조절
- α 가 1에 가까울수록 이전 정보에 큰 가중치 부여
- 보통 $\alpha=0.5, 0.9$ 를 사용

5.8 딥러닝이 사용하는 옵티마이저

5.8.2 적응적 학습률을 적용한 옵티마이저

- 고전적 SGD 옵티마이저에는 학습률 learning rate 이라는 하이퍼 매개변수가 존재

$$\text{고전적 SGD: } \mathbf{w} = \mathbf{w} - \rho \frac{\partial J}{\partial \mathbf{w}}$$

- 그래디언트는 오류가 작아지는 방향을 지시하지만, 얼마나 이동해야 최저점에 도달하는지 정보 부재
- 따라서 SGD 옵티마이저는 작은 학습률을 사용해 조금씩 이동하는 보수적인 정책을 사용
- 일반적으로 SGD는 학습률을 0.01을 기본값으로 사용하는 편인데 더 작은 값을 사용하는 경우도 많음




그림 5-16 학습률에 따른 수렴 특성

5.8 딥러닝이 사용하는 옵티마이저

5.8.2 적응적 학습률을 적용한 옵티마이저

- 고전적 SGD는 아래와 같이 고정된 학습률을 사용하지만, 상황에 맞게 학습률을 조절하는 적응적 학습률이 존재함

$$\text{고전적 SGD: } \mathbf{w} = \mathbf{w} - \rho \frac{\partial J}{\partial \mathbf{w}}$$

- 적응적 학습률을 적용한 옵티마이저에는 Adagrad, RMSprop, Adam 등이 있음
 - Adagrad : 이전 그래디언트를 누적한 정보를 이용하여 학습률을 적응적으로 설정하는 기법
 - RMSprop : 이전 그래디언트를 누적할 때 오래된 것의 영향 ρ 을 줄이는 정책을 사용하여 AdaGrad를 개선한 기법
 - Adam : RMSProp에 모멘텀 β_1 을 적용하여 RMSprop β_2 를 ρ 대신 사용을 개선한 기법

5.8 딥러닝이 사용하는 옵티마이저

5.8.3 옵티마이저 성능 비교 실험 (Fashion MNIST)

[프로그램5-11] 옵티마이저의 성능 비교: SGD, Adam, Adagrad, RMSprop

****옵티마이저 별로 CE Loss 기반으로 DNN 학습 실행**



```
80 if __name__ == '__main__':
81
82     # 로그용 디렉터리 정의 (1)
83     history = {name: {'train_acc': [], 'test_acc': [], 'train_loss': [], 'test_loss': []}
84                 for name in ['SGD', 'Adagrad', 'RMSprop', 'Adam']}
85
128 for optimizer_name in ['SGD', 'Adagrad', 'RMSprop', 'Adam']:
129
130     # 모델 정의
131     DNN = DeepNeuralNetwork(input_dim=784, hidden_dim=512, output_dim=10)
132     DNN = DNN.cuda()
133
134     if optimizer_name == 'SGD':
135         optimizer = torch.optim.SGD(DNN.parameters(), lr=0.001)
136     elif optimizer_name == 'Adagrad':
137         optimizer = torch.optim.Adagrad(DNN.parameters(), lr=0.001)
138     elif optimizer_name == 'RMSprop':
139         optimizer = torch.optim.RMSprop(DNN.parameters(), lr=0.001)
140     elif optimizer_name == 'Adam':
141         optimizer = torch.optim.Adam(DNN.parameters(), lr=0.001)
142
143     # 모델 학습
144     for iter in tqdm.tqdm(range(30)):
145         DNN, history[optimizer_name] = train_epoch(train_dataloader, optimizer, DNN, loss_ce, history[optimizer_name])
146         DNN, history[optimizer_name] = test_epoch(test_dataloader, optimizer, DNN, loss_ce, history[optimizer_name])
147
148
```

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p8-codingnote>

5.8 딥러닝이 사용하는 옵티마이저

5.8.3 옵티마이저 성능 비교 실험 (Fashion MNIST)

[프로그램5-11] 옵티마이저의 성능 비교: SGD, Adam, Adagrad, RMSprop



5.9 좋은 프로그래밍 스킬

- 프로그래밍 스킬의 중요성
 - 프로그래밍을 못하면 아무런 인공지능 프로그램도 만들 수 없음
 - 프로그래밍이 미숙하면 좋은 아이디어보다 디버깅에 에너지 소진
 - 프로그래밍은 인공지능에서 충분조건은 아니지만 핵심 필요조건
- 모듈화 하라
 - 좋은 프로그램을 짜기 위해 가장 먼저 할 일은 함수를 만들어 반복되는 코드를 줄이는 것
- 언어의 좋은 특성을 최대한 활용하라
 - 사례(②의 두 행을 간결하게 ①의 한 행으로 코딩)

```
print("SGD 정확률은", dmlp_sgd.evaluate(x_test, y_test, verbose=0)[1]*100)
```

①

```
res_sgd=dmlp_mse.evaluate(x_test, y_test, verbose=0)  
print("평균제곱오차의 정확률은", res_sgd[1]*100)
```

②

5.9 좋은 프로그래밍 스킬

- 점증적으로 코딩하라
 - 한번에 한가지 기능을 추가하고 옳게 작동하는지 확인하는 일을 반복
- 디자인 패턴이 몸에 배게 하라
 - 다른 프로그램과 공유하는 디자인 패턴에 대한 눈썰미
- 도구에 한없이 익숙해져라
 - 라이브러리 사용에 익숙
 - 통합개발환경 사용에 익숙
- 기초에 충실하라
 - 파이썬 기초 문법 익히기
 - 중요한 라이브러리 익히기
 - 기계학습의 기초 이론 등

5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

- 높은 성능을 발휘하는 모델을 찾으려면 객관적인 성능 평가가 필수임
- 가장 효과적인 방법은 여러 번 반복하고 평균을 취하는 교차 검증 기법

5.10.1 교차 검증을 이용한 옵티마이저 선택

- 딥러닝 라이브러리 (파이토치, 텐서플로우) 에는 교차 검증을 지원하는 클래스가 없음
- 딥러닝은 주로 대용량 데이터셋으로 수행하므로 교차 검증 없이 측정한 성능도 어느 정도 신뢰할 수 있다는 생각 때문임
- 따라서 필요시 교차검증을 하는 함수를 직접 만들어야 함


5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

- K-Fold 교차 검증을 위해 sklearn.model_selection 모듈 활용

클래스명	클래스 설명
<u>KFold</u>	<code>class sklearn.model_selection.KFold(n_splits=5, *, shuffle=False, random_state=None)</code> [source] K-Fold cross-validator. n_splits 수 : train, test 세트 합 shuffle : True설정 시 데이터셋 내의 순서를 섞어서 샘플링 random_state: seed 설정



5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

- K-Fold 교차 검증을 위해 sklearn.model_selection 모듈 활용

클래스명	클래스 설명
KFold.split	<code>split(X, y=None, groups=None)</code> [source] Generate indices to split data into training and test set.

`split(X, y=None, groups=None)` [\[source\]](#)

Generate indices to split data into training and test set.

Parameters:

X : array-like of shape (n_samples, n_features)

Training data, where `n_samples` is the number of samples and `n_features` is the number of features.

y : array-like of shape (n_samples,)

The target variable for supervised learning problems.

groups : object

Always ignored, exists for compatibility.

Yields:

“Yields” : 반복 (iteration) 할 때 하나씩 내보내는 값”을 뜻 함.

train : ndarray

The training set indices for that split.

test : ndarray

The testing set indices for that split.

3. 실제 코드 예시

python

[코드 복사](#)

```
from sklearn.model_selection import KFold
import numpy as np

X = np.arange(10)
kf = KFold(n_splits=5)

for train_index, test_index in kf.split(X):
    print("Train:", train_index, "Test:", test_index)
```

이 코드에서 `kf.split(X)` 는 제너레이터(generator) 를 반환하고,
`for` 문을 돌 때마다 `yield` 된 `(train_index, test_index)` 쌍을 하나씩 꺼냅니다.

```
Train: [2 3 4 5 6 7 8 9] Test: [0 1]
Train: [0 1 4 5 6 7 8 9] Test: [2 3]
Train: [0 1 2 3 6 7 8 9] Test: [4 5]
Train: [0 1 2 3 4 5 8 9] Test: [6 7]
Train: [0 1 2 3 4 5 6 7] Test: [8 9]
```


5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

- K-Fold 교차 검증을 위해 sklearn.model_selection 모듈 활용

클래스명	클래스 설명
StratifiedKFold	<code>class sklearn.model_selection.StratifiedKFold(n_splits=5, *, shuffle=False, random_state=None)</code>[source] Class-wise stratified K-Fold cross-validator. 교차 검증 시 주의해야할 사항으로 train/test 셋에서 각 클래스의 비율이 동일하게 분포해야 한다는 점.이렇게 각 라벨의 비율을 동일하게 뽑고 싶다면, StratifiedKFold 함수를 통하여 데이터셋 분할을 진행해야 함. StratifiedKFold 함수의 argument 종류와 전반적인 사용법은 KFold 함수와 거의 동일 다만, 분할 과정에서 라벨 분포의 정보도 받아와야 하므로 for 문 내에서 kf.split(X) 대신 kf.split(X, y) 형태로 선언한 점에서 차이가 있음

5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

- K-Fold 교차 검증을 위해 sklearn.model_selection 모듈 활용

클래스명	클래스 설명
StratifiedKFold.split	split(X, y, groups=None) [source] Generate indices to split data into training and test set.

```
1 from sklearn.model_selection import StratifiedKFold
2 import numpy as np
3
4 # 예시 데이터 (X: 샘플 ID, y: 클래스 레이블)
5 X = np.arange(10)
6 y = np.array([0, 0, 0, 0, 1, 1, 1, 1, 1, 1]) # 클래스 0과 1의 비율이 다름
7
8 # StratifiedKFold 객체 생성
9 skf = StratifiedKFold(n_splits=3)
10
11 # split()은 yield를 사용해서 (train_idx, test_idx)를 하나씩 내보냄
12 for fold, (train_index, test_index) in enumerate(skf.split(X, y)):
13     print(f"Fold {fold+1}")
14     print("  Train indices:", train_index)
15     print("  Test indices :", test_index)
16     print("  Train labels :", y[train_index])
17     print("  Test labels  :", y[test_index])
18     print()
19
```

```
Fold 1
  Train indices: [2 3 6 7 8 9]
  Test indices : [0 1 4 5]
  Train labels : [0 0 1 1 1 1]
  Test labels  : [0 0 1 1]

Fold 2
  Train indices: [0 1 3 4 5 8 9]
  Test indices : [2 6 7]
  Train labels : [0 0 0 1 1 1 1]
  Test labels  : [0 1 1]

Fold 3
  Train indices: [0 1 2 4 5 6 7]
  Test indices : [3 8 9]
  Train labels : [0 0 0 1 1 1 1]
  Test labels  : [0 1 1]
```

VS

```
1 from sklearn.model_selection import KFold
2 import numpy as np
3
4 # 예시 데이터 (X: 샘플 ID, y: 클래스 레이블)
5 X = np.arange(10)
6 y = np.array([0, 0, 0, 0, 1, 1, 1, 1, 1, 1]) # 클래스 0과 1의 비율이 다름
7
8 # KFold 객체 생성
9 skf = KFold(n_splits=3)
10
11 # split()은 yield를 사용해서 (train_idx, test_idx)를 하나씩 내보냄
12 for fold, (train_index, test_index) in enumerate(skf.split(X)):
13     print(f"Fold {fold+1}")
14     print("  Train indices:", train_index)
15     print("  Test indices :", test_index)
16     print("  Train labels :", y[train_index])
17     print("  Test labels  :", y[test_index])
18     print()
19
```

```
Fold 1
  Train indices: [4 5 6 7 8 9]
  Test indices : [0 1 2 3]
  Train labels : [1 1 1 1 1 1]
  Test labels  : [0 0 0 0]

Fold 2
  Train indices: [0 1 2 3 7 8 9]
  Test indices : [4 5 6]
  Train labels : [0 0 0 0 1 1 1]
  Test labels  : [1 1 1]

Fold 3
  Train indices: [0 1 2 3 4 5 6]
  Test indices : [7 8 9]
  Train labels : [0 0 0 0 1 1 1]
  Test labels  : [1 1 1]
```

5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

```
85 if __name__ == '__main__':
86
87     ## 데이터셋 준비 - MNIST, FashionMNIST
88     MNIST_training_data = datasets.FashionMNIST(root='data', train=True, download=True, transform=ToTensor())
89     MNIST_test_data = datasets.FashionMNIST(root='data', train=False, download=True, transform=ToTensor())
90
91
92     ## KFold 로그 저장
93     k = 5
94     kfold_histroy = list()
95
96     ## KFold 반복문 안에서 Dataset을 slicing하기 위해 Tensor 변환
97     x_train = MNIST_training_data.data
98     y_train = MNIST_training_data.targets
99     x_train = x_train.type(torch.float32)
100
101     ## KFold 반복문
102     for train_index, val_index in KFold(k).split(x_train):
103
104
105
106     # 로그를 디렉토리
107     history = dict()
108     history['SGD'] = dict()
109     history['Adagrad'] = dict()
110     history['RMSprop'] = dict()
111     history['Adam'] = dict()
112
113     xtrain, xval = x_train[train_index], x_train[val_index]
114     ytrain, yval = y_train[train_index], y_train[val_index]
115
116     _MNIST_training_data = torch.utils.data.TensorDataset(xtrain, ytrain)
117     _MNIST_test_data = torch.utils.data.TensorDataset(xval, yval)
118
119     ## 배치 단위 데이터셋 준비
120     train_dataloader = torch.utils.data.DataLoader(_MNIST_training_data, batch_size=128)
121     test_dataloader = torch.utils.data.DataLoader(_MNIST_test_data, batch_size=128, shuffle=False)
122
123     for optimizer_name in ['SGD', 'Adagrad', 'RMSprop', 'Adam']:
124
125         # 모델 정의
126         DNN = DeepNeuralNetwork(input_dim=784, hidden_dim=512, output_dim=10)
127         DNN = DNN.cuda()
128
129         if optimizer_name == 'SGD':
130             optimizer = torch.optim.SGD(DNN.parameters(), lr=0.001)
131         elif optimizer_name == 'Adagrad':
132             optimizer = torch.optim.Adagrad(DNN.parameters(), lr=0.001)
133         elif optimizer_name == 'RMSprop':
134             optimizer = torch.optim.RMSprop(DNN.parameters(), lr=0.001)
135         elif optimizer_name == 'Adam':
136             optimizer = torch.optim.Adam(DNN.parameters(), lr=0.001)
137
138         history[optimizer_name]['train_acc'] = list()
139         history[optimizer_name]['test_acc'] = list()
140         history[optimizer_name]['train_loss'] = list()
141         history[optimizer_name]['test_loss'] = list()
142
143         # 모델 학습
144         for iter in tqdm.tqdm(range(30)):
145             DNN, history[optimizer_name] = train_epoch(train_dataloader, optimizer, DNN, loss_mse, history[optimizer_name])
146             with torch.no_grad():
147                 DNN, history[optimizer_name] = test_epoch(test_dataloader, optimizer, DNN, loss_mse, history[optimizer_name])
148
149     kfold_histroy.append(history)
```

98-100행 K-Fold slicing을 위해 Tensor로 자료형 변경

103행 K-Fold 검증을 위해 k번 돌아가는 반복문 정의

113-117행 K-Fold 검증을 위해 train/val 데이터 정의

147행 옵티마이저 별 validation 정확도 저장

150행 K-Fold 검증을 위해 k별 validation 정확도 기록

<https://www.kaggle.com/code/yukyungchoi/2025-2-ai-w5-p9-codingnote>

5.10 교차 검증을 이용한 하이퍼 매개변수 최적화


5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

```
1 import matplotlib.pyplot as plt
2
3 #-- KFold 결과 출력
4 test_acc_dict = dict()
5 test_acc_dict['SGD'] = list()
6 test_acc_dict['Adagrad'] = list()
7 test_acc_dict['RMSprop'] = list()
8 test_acc_dict['Adam'] = list()
9
10 for optimizer_name in ['SGD', 'Adagrad', 'RMSprop', 'Adam']:
11     for idx in range(len(kfold_histroy)):
12         test_acc_dict[optimizer_name].append(kfold_histroy[idx][optimizer_name]['test_acc'][-1])
13
14
15 # 박스 플롯으로 정확률 표시
16 plt.grid()
17 plt.boxplot([test_acc_dict['SGD'], test_acc_dict['Adagrad'], test_acc_dict['RMSprop'], test_acc_dict['Adam']], labels=['SGD', 'Adagrad', 'RMSprop', 'Adam'])
```

4-8행 각각의 K 마다 마지막 epoch에 대한 정확도를 담아줄 list 정의

17행 boxplot을 활용해 K-Fold 교차 검증 시각화




5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

- 성능 분석용 데이터 시각화를 위해 Matplotlib 모듈의 boxplot 사용

클래스명	클래스 설명
matplotlib.pyplot	<code>matplotlib.pyplot.boxplot(x, *, notch=None, sym=None, vert=None, orientation='vertical', whis=None, positions=None, widths=None, patch_artist=None, bootstrap=None, usermedians=None, conf_intervals=None, meanline=None, showmeans=None, showcaps=None, showbox=None, showfliers=None, boxprops=None, tick_labels=None, flierprops=None, medianprops=None, meanprops=None, capprops=None, whiskerprops=None, manage_ticks=True, autorange=False, zorder=None, capwidths=None, label=None, data=None)</code> [source] Draw a box and whisker plot.



구성요소	설명	수학적 정의
박스(Box)	데이터의 중간 50% (IQR: Interquartile Range)를 나타냄	$Q1 \sim Q3$ (1사분위수 ~ 3사분위수)
중앙선(Median line)	박스 내부의 굵은 선	$Q2$ (중앙값, Median)
박스 위끝(Upper quartile)	박스의 윗 경계선	$Q3$ (75% 지점)
박스 아래끝(Lower quartile)	박스의 아랫 경계선	$Q1$ (25% 지점)
수염(Whiskers)	박스 바깥으로 뻗은 선, 데이터의 '범위'를 표현	$Q1 - 1.5 \times IQR \sim Q3 + 1.5 \times IQR$ 범위 내 데이터
이상치(Outliers)	수염 밖의 점	위 범위 밖 데이터
평균(mean)	기본 boxplot에서는 표시되지 않음 → 옵션 <code>showmeans=True</code> 로 표시 가능	데이터의 산술 평균


5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.1 교차 검증을 이용한 옵티 마이저 성능 선택

[프로그램5-12] K-Fold 교차 검증을 활용한 옵티마이저의 성능 비교

- 성능 분석용 데이터 시각화를 위해 Matplotlib 모듈의 boxplot 사용

```
plt.grid()  
plt.boxplot([test_acc_dict['SGD'], test_acc_dict['Adagrad'], test_acc_dict['RMSprop'], test_acc_dict['Adam']], labels=['SGD', 'Adagrad',  
'RMSprop', 'Adam'], showmeans=True, meanline=True)
```



주황색 실선 : 중위값
녹색 점선 : 평균 값

5.10 교차 검증을 이용한 하이퍼 매개변수 최적화

5.10.2 과도한 계산 시간과 해결책

- 교차 검증은 시간이 많이 소요됨, 즉 성능 검증에 대한 신뢰도가 높아지는 대신 시간이 걸림
 - 학습을 한번 마치는데 t 라는 시간이 걸린다면, kt 만큼 시간이 지나야 옵티마이저 하나의 성능 측정이 끝남
 - [프로그램5-12]는 옵티마이저 4개를 평가하므로 총 $4kt$ 만큼의 시간이 걸림
 - [프로그램5-12]는 하이퍼 매개변수를 모두 고정시키고 최적화를 수행
- 딥러닝에서 만일 하이퍼 매개변수 최적화를 제대로 하려면 훨씬 많은 시간이 걸림
 - 데이터셋의 크기가 기존 토이 데이터셋보다 훨씬 큼
 - 딥러닝은 하이퍼 매개변수가 아주 많음
 - 예를들어, 옵티마이저{SGD, Adam, Adagrad, RMSprop}, 학습률{0.01, 0.005, 0.001, 0.0005, 0.0001, 0.00005, 0.00001}, 미니배치 크기{32, 64, 128, 256, 512, 1024}의 조합을 최적화한다면 총 168개 조합에 대해서 학습을 진행해야 함
- 딥러닝은 GPU를 이용함으로써 과도한 계산 시간 문제를 해결 가능함

Pytorch 를 이용한 MLP 실습 과제

- 제출 방식 : 이메일로 보고서 제출
 - 마감 : 10월 20일 (월) 23시 59분
 - 이메일 주소 : admin@rcv.sejong.ac.kr
 - 이메일 제목 : [2025-2] [인공지능] 7주차 과제 제출 (학번_이름)
 - 보고서 분량 제한 없음
- [문제1] Fashion MNIST
 - MLP+ADAM, MLP+SGD, MLP+Adagrad, MLP+RMSprop 비교 실습
 - 가장 적절한 옵티마이저와 파라미터 값을 찾아 현재 설정된 베이스라인을 해결하시오.
 - <https://www.kaggle.com/t/ce19b0c6440a4740b8bd048875c0142e>