

세밀한 개방형 어휘 객체 탐지를 위한 P2R 후처리 방법

P2R: Post-processing Method for Fine-Grained Open-Vocabulary Object Detection

신 인택¹ · 김 현우² · 박 성준² · 최 유경[†]

Intaek Shin¹ · Hyunwoo Kim² · Sungjune Park² · Yukyung Choi[†]

Abstract: Open-Vocabulary Object Detection (OVOD) has recently emerged as a promising paradigm for recognizing arbitrary objects without explicit category supervision. Among them, models such as Grounding DINO have shown strong zero-shot detection ability on conventional OVOD benchmarks. However, their performance dramatically drops when evaluated under the recently proposed 3F-OVD task, which requires fine-grained reasoning over detailed, attribute-level captions rather than coarse category names. This performance gap highlights the limitation of current OVOD models in handling phrase-level redundancy and fragmented predictions. To address this, we propose a post-processing framework that systematically filters false positives and consolidates fragmented predictions by analyzing spatial overlap and phrase semantics. The framework consists of three sequential stages: Phrase Merging, Phrase Filtering, and Weighted Score Re-ranking that progressively refine detection results from spatial consolidation to confidence re-ranking. Our method yields +13.1% and +10.0% relative mAP gains on the NEU-171K-C fine-grained and coarse-grained settings, demonstrating improved detection reliability across multiple granularity levels.

Keywords: Open-Vocabulary Object Detection, Fine-Grained Recognition, Training-Free Calibration, Post-Processing, Robot Perception

1. 서 론

로봇 비전 시스템과 자율주행 환경에서는 주변 객체를 정확하고 상황에 맞게 인식하는 능력이 필수적이다. 단순히 ‘자동차’나 ‘사람’을 구분하는 수준을 넘어, 세부 모델이나 제품의 변형

규격과 같은 세밀한 인식 능력은 복잡한 실세계 환경에서 안전한 판단과 정밀한 동작을 가능하게 한다.

그러나 기존의 객체 탐지 모델은 사전에 정의된 고정 클래스 집합에 대해서만 작동하므로, 학습 시점에 포함되지 않은 새로운 객체나 개념에 대해서는 올바르게 인식하기 어렵다는 한계가 있다. 이러한 제약을 완화하기 위해 Open-Vocabulary Object Detection (OVOD) 이 제안되었다. OVOD는 이미지와 텍스트를 함께 학습한 대규모 비전-언어 모델의 사전학습 지식을 활용하여, 사전에 정의되지 않은 대상도 자연어 질의만으로 탐지할 수 있도록 한다. 이는 대규모 이미지-텍스트 쌍으로 사전학습된 CLIP^[1] 모델의 등장으로 가능해졌으며, 대규모 이미지-텍스트 사전학습을 탐지기에 활용한 모델들^[3-5] 이 OVOD의 주요 기반으로 사용되고 있다.

그러나 기존 OVOD 평가들은 주로 ‘자동차’, ‘고양이’, ‘의자’ 등 보편적인(coarse-grained) 수준의 카테고리 명칭 중심으로 설계되어 있었기 때문에, 모델이 세밀한 속성이나 형태적 차이를 구분하는 능력을 제대로 측정하기 어렵다는 한계가 있었다. 이에 따라 실세계 시나리오에서 요구되는 언어적, 시각적 세

※ This work was supported by IITP under the metaverse support program to nurture the best talents (IITP-2025-RS-2023-00254529) grant funded by the Korea government (MSIT)(40%), in part by the IITP-ICAN grant funded by the Korea government (MSIT) (IITP-2025-RS-2022- 00156345)(30%), and in part by Unmanned Vehicles Core Technology Research and Development Program through the NRF and Unmanned Vehicle Advanced Research Center (UVARC) funded by the Ministry of Science and ICT, the Republic of Korea (NRF-2023M3C1C1A01098408)(30%).

1. Undergraduate, Student Department of Intelligent Mechatronics Engineering in Sejong University, Seoul, Korea (itshin@rcv.sejong.ac.kr)

2. Graduate Student, Department of Intelligent Mechatronics Engineering in Sejong University, Seoul, Korea (hwkim@rcv.sejong.ac.kr, sjpark@rcv.sejong.ac.kr)

† Associate Professor, Corresponding author: Department of Artificial Intelligence and Robotics in Sejong University, Seoul, Korea (ykchoi@sejong.ac.kr)

밀성을 평가하기 위해 3F-OVD^[2] 과제가 새롭게 제안되었다.

3F-OVD는 각 클래스에 대해 고정된 라벨 대신, 세밀한 시각 속성(엠블럼 모양, 차체 형태, 전조등 구조 등)을 묘사한 캡션을 제공하며, 모델이 이 설명을 기반으로 정확한 객체 위치를 찾아야 한다. [Table 1]은 NEU-171K-C 데이터셋에서 사용되는 예시 캡션을 보여준다. 3F-OVD 평가 결과에 따르면, 현존 OVOD 모델들은 이 설정에서 매우 낮은 성능을 보인다. 특히 Grounding DINO^[3]는 기존 OVOD 과제에서는 상대적으로 높은 정확도를 보였음에도, 세밀한 클래스 구분에서는 예측의 중복성과 구절 단위의 과도한 반응으로 인해 정확도가 급격히 저하되었다. 이는 모델이 각 캡션 구절마다 별도의 박스를 생성하는 구조적 특성 때문에, 중복된 박스와 불필요한 오탐지가 대량으로 발생하기 때문이다.

이러한 한계를 해결하기 위해 Phrase-to-Region Re-ranking (P2R) 이라 명명한 후처리 프레임워크를 제안한다. P2R은 세 단계로 구성된 순차적 파이프라인으로, 중복 박스를 병합하여 탐지 결과를 공간적으로 통합하는 Phrase Merging 단계, 의미적으로 불필요하거나 중복되는 구절을 제거하는 Phrase Filtering 단계, 그리고 남은 박스들의 공간적 일관성과 신뢰도를 종합적으로 고려해 최종 점수를 재정렬하는 Weighted Score Re-ranking 단계로 이루어진다. 이 과정을 통해 Grounding DINO의 세밀 인식 성능을 향상시키면서도, 모델 재학습 없이 탐지 결과의 신뢰도를 크게 개선할 수 있다.

2. 제안 방법론

2.1 데이터셋

본 연구는 세밀한 수준의 객체 인식 성능을 검증하기 위해 NEU-171K-C^[2] 데이터셋을 사용하였다. 이 데이터셋은 총 89,363 장의 차량 이미지와 598 개의 세부 차종 어노테이션으로 구성되어 있으며, 각 클래스는 고유한 모델명과 함께 형태, 색상, 로고, 구조적 특징 등을 서술한 자연어 캡션을 포함한다. [Table 1]은 NEU-171K-C에서 사용되는 예시 캡션을 보여준다.

또한, 세밀도 수준(fine-to-coarse)에 따른 후처리 효과를 분석하기 위해, 전체 598개 클래스를 시각적·기능적 유사성을 기준으로 통합하여 6개의 슈퍼 카테고리(超)로 재구성하였고, 6개의 카테고리에 해당하는 캡션을 기존 데이터셋과 같이 생성하여 캡션을 통한 평가 방식이 가능하게 하였다. 이를 통해 세밀한 인식 뿐만 아니라 아니라 상위 개념 단위에서도 제안된 프레임워크의 성능 일관성을 평가하였다. [Table 2]는 각 슈퍼 카테고리(超)와 대표적인 하위 클래스 예시를 제시한다.

[Table 1] Example captions from the NEU-171K-C dataset. Each caption describes fine-grained visual attributes such as emblem, body shape, and headlight structure.

Class name	Example caption
Fiat Feixiang	"The car model is a sedan, with a red circular emblem... ,The front lights of the car ..."
Ford Focus	"The car is a sedan, with a round emblem consisting of a 'V' letter... , The front lights are conjoined..."
BMW X5	"The car type is a Sport Utility car (SUV). The emblem is divided into four..."

[Table 2] Coarse-level category configuration used for evaluation. Each group merges fine-grained sub-classes sharing similar visual and functional characteristics.

Super category	Sub-classes examples
sedan	"Ford focus", "Toyota Corolla"
sport utility vehicle	"Jeep FreedomMan", "Haver m6"
van	"Wuling Glory", "Baic Viwang306"
multi purpose vehicle	"Benz Rclass", "Honda Odyssey"
pickup truck	"Jiangling Yuhu5", "Toyota HILUX"
coupe	"Haver h6coupe", "Audi rs7"


2.2 문제 정의

3F-OVD^[2]는 Grounding DINO와 같은 OVOD 모델의 세밀한 객체의 인식 한계를 완화하기 위해, 예측 이미지의 해상도가 지나치게 크거나(960×960 이상), 작을(14×14 이하) 결과를 제거하는 필터링 기법을 제안했다. 이 접근은 일정 수준의 오탐지 억제에는 효과적이지만, 모델의 예측이 문장 내 구문 단어라는 구조적 특성을 고려하지 못한다는 근본적인 한계를 지닌다.

Grounding DINO는 각 구절 단위로 독립적으로 예측을 수행하기 때문에, 동일 객체에 대해 "SUV", "a black SUV", "Black"과 같은 유사 구문이 중복 탐지되거나, "a", "the", "with" 등 불용어가 개별 객체로 잘못 탐지되는 문제가 발생한다. 이러한 현상은 단순한 크기 기반 필터링으로는 해결할 수 없으며, 모델의 언어적 예측 구조를 반영한 정교한 후처리 접근이 필요함을 시사한다.

2.3 제안하는 후처리 프레임워크

본 연구에서는 Grounding DINO의 구문 단위 예측 특성으로 인해 발생하는 중복 탐지와 오탐지 문제를 해결하기 위해, 세밀한 캡션 기반 탐지(3F-OVD) 환경에 최적화된 3 단계 후처리 프레임워크 P2R (Phrase-to-Region Re-ranking)을 제안한다. P2R은 구문 병합 (Phrase Merging, PM), 구문 필터링 (Phrase Filtering, PF), 신뢰도 재정렬 (Weighted Score Re-ranking, WSR)의 세 단계로 구성된다. 각 단계는 앞선 단계의 출력을 입



[Fig. 1]: Overall framework of the proposed post-processing pipeline. The proposed P2R framework proceeds through three sequential stages: Phrase Merging (PM), Phrase Filtering (PF), and Weighted Score Re-ranking (WSR).

력으로 받아 예측 품질을 점진적으로 향상시키며, 전체 절차는 [Fig. 1]에 요약되어 있다.

2.3.1 구문 병합 (Phrase Merging, PM)

Grounding DINO는 캡션의 각 구문 단위로 독립적인 박스 예측을 수행하므로, 동일한 객체에 대해 “SUV”, “a black SUV”, “black” 과 같은 유사 구문이 서로 겹치는 박스로 중복 탐지될 수 있다. 구문 병합을 위해 먼저 예측 박스 집합 $B = \{(\mathbf{b}_i, s_i) | i = 1, \dots, N\}$ 을 신뢰도 s_i 기준으로 내림차순 정렬한 뒤, 상위 박스부터 IoU 값이 0.5 이상인 박스들을 클러스터 C_j 로 묶는다. 각 클러스터 C_j 내에서 최대 신뢰도를 가진 박스 $\mathbf{b}_{\max}$ 를 대표 박스로 선정하고, 그 신뢰도 $s_{\max}$ 를 클러스터 크기 $|C_j|$ 에 비례하여 식 (1)과 같이 보정한다.

$$s'_j = \min((s_{\max}) \times (1 + \alpha \times (|C_j| - 1)), 1.0) \quad (1)$$

여기서 $|C_j|$ 는 클러스터 내 박스 개수, $\alpha = 0.1$ 은 신뢰도 강화 계수이며 s'_j 는 병합 후 대표 박스의 보정된 점수이다. 즉 동일 객체에 중복되는 박스가 많을수록 탐지의 신뢰성이 높다고 가정하여 점수를 상향 보정한다.

2.3.2 구문 필터링 (Phrase Filtering, PF)

Grounding DINO는 언어적으로 의미가 없는 불용어 (예: “a”, “the”, “with”) 또는 의미가 불완전한 세 단어 미만의 구문 (예: “red circular”, “V letter”)에 대한 예측이 불필요하게 생성되는 경향이 있다. 이를 방지하기 위해 불용어 집합에 속하거나 구문 길이가 3자 미만인 예측을 제거하였다. 이 단계는 캡션 내 세부적 속성이 객체로 오인식되는 것을 방지하며, 특히 세밀한 수준의 탐지에서 정밀도 향상에 기여한다.

2.3.3 신뢰도 재정렬 (Weighted Score Re-ranking, WSR)

신뢰도 재정렬 단계에서는 박스의 공간적 타당성을 고려하여 신뢰도를 재조정한다. Grounding DINO의 예측은 크기와 위치 제약이 없어, 극단적으로 작거나 가장자리에 위치한 박스가 과도한 점수를 받는 문제가 있다. 이를 보완하기 위해 박스 $\mathbf{b}_i$ 의 면적과 중심 좌표를 이용해 점수를 식 (2)와 같이 보정한다.

$$s''_j = s'_j \times f_{\text{size}}(\mathbf{b}_j) \times f_{\text{pos}}(\mathbf{b}_j) \quad (2)$$

(a) 면적 가중치 함수 f_{size}

박스 $\mathbf{b}_j$ 의 면적 A_j 와 이상적인 객체 면적인 $A_{\text{ideal}} = 90,000$ (300×300)을 사용해 면적 비율 r 을 정의한다.

$$r = \frac{A_j}{A_{\text{ideal}}} \quad (3)$$

$$f_{\text{size}}(\mathbf{b}_j) = \begin{cases} s(r), & 0.5 \leq r \leq 3.0 \\ 0.95, & r < 0.5 \text{ or } r > 3.0 \end{cases} \quad (4)$$

식 (4)에서 $s(r) = 1 + 0.03 \times \min(r, 2.0)$ 이다. 즉 박스의 면적이 이상적인 면적의 2배에 가까울수록 높은 면적 가중치를 가지게 되며 너무 작거나 큰 박스들에는 면적 가중치에 패널티를 부여한다.

(b) 위치 가중치 함수 f_{pos}

박스 중심 좌표를 (x_m, y_m) , 이미지 중심 좌표를 (x_c, y_c) 라고 할 때, 두 중심 간 거리 d_j 를 식 (5)와 같이 정의한다.

$$d_j = \sqrt{(x_m - x_c)^2 + (y_m - y_c)^2} \quad (5)$$

$$f_{\text{pos}}(\mathbf{b}_j) = \begin{cases} 1.02, & d_j \leq 200 \\ 1.0, & d_j > 200 \end{cases} \quad (6)$$

식 (6)에서 d_j 가 기준값인 200픽셀보다 작거나 같다면 위치 가중치값이 증가하고, 200픽셀보다 크다면 위치 가중치값이 감소하게 된다. 결과적으로 위치 가중치 함수는 최대 +2%, 면적 가중치 함수는 최대 +6%, 최소 -5%의 신뢰도 변화를 유도하며, 전체적으로 최대 +8.1%의 신뢰도 향상을 달성한다. 이 과정을 통해 모델 파라미터를 변경하지 않고도 탐지 순위를 재조정하여 예측의 안정성과 일관성을 개선할 수 있다.

3. 실험 결과

제안한 후처리 파이프라인(PM → PF → WSR)의 성능을 세

[Table 4] Quantitative comparison between the original 3F-OVD filtering method (ABF) and the proposed P2R framework on fine-grained (FG) and coarse-grained (CG) settings.

	Method	mAP(%)	mAP50(%)	vs. Baseline
FG	Grounding DINO	0.119	0.151	-
	+ABF	0.124	0.157	+4.2%
	+P2R	0.135	0.167	+13.1%
	+(P2R + ABF)	0.140	0.173	+17.4%
CG	Grounding DINO	4.050	5.263	-
	+ABF	4.320	5.621	+6.7%
	+P2R	4.454	5.704	+10.0%
	+(P2R + ABF)	4.640	5.957	+14.6%

밀(fine-grained)과 보편(coarse-grained) 설정에서 평가하였다. 후처리인 Grounding DINO의 기본 예측을 입력으로 하며, 각 단계를 순차적으로 적용하였다. [Table 4]는 기존 3F-OVD의 면적 기반 필터링 기법(Area-based Filtering, ABF)과 제안한 P2R 프레임워크의 비교 결과를 보여준다. 3F-OVD의 필터링 기법은 일부 오탐지를 억제했으나 구문 중복 문제는 해결하지 못한 반면, P2R은 언어적 및 공간적 일관성을 보장하여 세밀·보편 양쪽 설정에서 더 안정된 탐지 결과를 보였다. 두 방법을 결합했을 때 가장 균형 잡힌 성능을 확인할 수 있었다.

각 단계별 변화를 분석한 [Table 5]에 따르면, PM (Phrase Merging) 단계는 중복 박스를 통합하지만 서로 다른 객체가 잘못 병합되는 경우 성능이 일시적으로 저하되었다. PF (Phrase Filtering)는 병합 후 남은 불용어 및 짧은 구문을 제거하여 정밀도를 회복시켰으며, WSR (Weighted Score Re-ranking)은 박스의 면적과 위치 정보를 반영해 신뢰도를 재정렬함으로써 탐지 순위를 안정화하였다. 결과적으로 P2R 파이프라인은 Grounding DINO의 예측을 보다 일관되고 의미적으로 정제된 출력으로 변환하였다.

4. 결론

본 연구는 세밀한 캡션 기반 탐지(3F-OVD) 환경에서 Grounding DINO가 보이는 구문 중복 및 문장 파편화 문제를 완화하기 위한 P2R 후처리 프레임워크를 제안한다.

제안된 세 가지 모듈(Phrase Merging, Phrase Filtering, Weighted Score Re-ranking)은 모델의 파라미터를 수정하지 않고도 적용 가능하며, 중복된 구문을 통합하고 의미적 불용어를 제거하며 공간적 신뢰도를 보정함으로써 탐지 결과의 일관성과 정밀도를 향상시켰다. 실험 결과, 제안한 프레임워크는 NEU-171K-C 데이터셋에 대해 fine-grained 설정에서 +13.1%, coarse-grained 설정에서 +10.0%의 상대적 mAP 향상을 달성

[Table 5] Ablation results of the proposed P2R pipeline on Grounding DINO in fine-grained (FG) and coarse-grained settings (CG).

	PM	PF	WSR	mAP(%)	mAP50(%)	vs. Baseline
FG				0.119	0.151	-
	✓			0.118	0.149	-0.8%
	✓	✓		0.125	0.154	+5.0%
	✓	✓	✓	0.135	0.167	+13.1%
CG				4.050	5.263	-
	✓			3.942	5.123	-2.6%
	✓	✓		4.454	5.704	+6.9
	✓	✓	✓	4.640	5.957	+10.0%

하였다. 이는 후처리만으로도 기존 OVOD 모델의 세밀도 인지 능력을 효율적으로 보정할 수 있음을 보여준다. 또한 본 연구에서 제안하는 P2R은 로봇 비전 시스템에서도 활용 가능성을 가진다. 자율주행 로봇의 객체 인식, 조작 로봇의 목표 부품 식별 등에 본 프레임워크를 적용하면, 구문 중복 제거와 신뢰도 재정렬을 통해 인식의 안정성을 향상시킬 수 있다. 향후에는 본 방법을 다른 OVOD 모델(ViLD, Detec 등)에 적용하여 모델 일반화 성과를 확장하고, 구문 의미론적 유사도나 어휘 임베딩을 활용한 자동 병합 전략으로 발전시킬 수 있을 것이다.

References

- [1] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever "Learning transferable visual models from natural language supervision," in Proceedings of the International Conference on Machine Learning, pp. 8748–8763, 2021.
- [2] Ying Liu, Yijing Hua, Haojiang Chai, Yanbo Wang, TengQi Ye, "Fine-grained open-vocabulary object detection with fine-grained prompts: Task, dataset and benchmark," in Proceedings of the IEEE International Conference on Robotics and Automation, Yokohama, Japan, pp. 13860–13867, 2025.
- [3] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, Q. Jiang, C. Li, J. Yang, H. Su, J. Zhu, and L. Zhang, "Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 6468–6477, 2023.
- [4] X. Zhou, R. Girdhar, A. Joulin, P. Krähenbühl, and I. Misra, "Detecting twenty-thousand classes using image-level supervision," in Proceedings of the European Conference on Computer Vision, pp. 350–368, Springer, Cham, 2022.
- [5] X. Gu, T.-Y. Lin, W. Kuo, and Y. Cui, "Open-vocabulary object detection via vision and language knowledge distillation," in Proceedings of the International Conference on Learning Representations, Article No. 18 pages, 2022.